



Bachelorthesis

Personalisierung von Chatbots im
Unternehmenskontext auf Basis
konversationsbasierter Nutzerpräferenzen

Prüfer:

Prof. Dr. Yvonne Gorniak

Verfasser:

Fabio Mirabile

102247

Auf dem Anger 4

33014 Bad Driburg

Wirtschaftsinformatik

Business Process Management

Eingereicht am:

2. Juni 2026

Sperrvermerk

Die vorgelegte Arbeit mit dem Titel „Adaptive Entscheidungsfindung in lernenden Chatbots auf Grundlage konversationsbasierter Nutzerpräferenzen“ beinhaltet vertrauliche Informationen und Daten von Phoenix Contact GmbH & Co. KG und der mit diesem verbundenen Unternehmen. Diese Arbeit darf nur vom Erst- und Zweitgutachter sowie berechtigten Mitgliedern des Prüfungsausschusses eingesehen werden. Eine Vervielfältigung und Veröffentlichung der Arbeit ist auch auszugsweise nicht erlaubt. Dritten darf diese Arbeit nur mit der ausdrücklichen Genehmigung von Phoenix Contact GmbH & Co. KG zugänglich gemacht werden. Zur Überprüfung von Plagiatsvergehen darf die Arbeit oder Teile davon einer Untersuchungsinstanz in Form einer Plagiat-Software vorgelegt werden. Der Sperrvermerk ist somit im Fall einer Plagiatsprüfung nicht wirksam.

Inhaltsverzeichnis

Sperrvermerk	II
Abbildungsverzeichnis	V
Listingverzeichnis	VI
1 Einleitung	1
1.1 Problemstellung	1
1.2 Zielsetzung	2
1.3 Abgrenzung	2
1.4 Vorgehensweise	2
2 Theoretische Grundlagen	3
2.1 Large Language Models	3
2.1.1 Definition und Hintergrund	3
2.1.2 Funktionsweise	3
2.1.3 Fähigkeiten und Limitierungen	4
2.1.4 Prompting und Kontextverarbeitung	4
2.1.5 Nutzung über APIs	6
2.2 Chatbots im Unternehmenskontext	6
2.2.1 Definition und Hintergrund von Chatbots	6
2.2.2 Retrieval Augmented Generation	6
2.3 Forschungsansatz und Methodik	8
2.3.1 Design Science Research	8
2.3.2 Methodik	9
3 Stand der Forschung	9
3.1 Personalisierte LLMs	10
3.2 Chat Historie	10
3.3 RAG Ansätze	10
4 Praxisteil	12
4.1 Vorstellung des Praxisunternehmens	12
4.2 Ist-Analyse	12
4.3 Identifikation des Problemraums	16

4.3.1	Schwächenanalyse	16
4.3.2	Rahmenbedingungen	17
4.3.3	Ziele	17
5	Evaluation	19
	Anhang	20
	Quellenverzeichnis	23
	Ehrenwörtliche Erklärung	24

Abbildungsverzeichnis

Abbildung 1: Typischer RAG Prozess	7
Abbildung 2: Design Science Research Method (DSRM) Prozess Modell . .	9
Abbildung 3: PIA Architektur	15
Abbildung 4: Aktuelle Schaltlogik des Funktionsbausteins	21
Abbildung 5: Ansicht im Anlagen Ordner	21
Abbildung 6: Ergebnisse des Zeitvergleiches	22

Listingverzeichnis

1 Einleitung

1.1 Problemstellung

Der Einsatz von Chatbots in Unternehmen hat in den vergangenen Jahren deutlich an Bedeutung gewonnen. Insbesondere durch die Fortschritte im Bereich leistungsfähiger Large Language Models (LLMs) haben sich Chatbots zu einem zentralen Bestandteil der digitalen Unternehmensinfrastruktur entwickelt. Sie können sowohl Kunden als auch Mitarbeitende in unterschiedlichen Anwendungsszenarien unterstützen, indem sie Informationen bereitstellen, Prozesse automatisieren oder Handlungsempfehlungen ableiten.

Auch das Unternehmen Phoenix Contact hat im Zuge dieser Entwicklungen einen Enterprise-Chatbot in den operativen Betrieb integriert. Dieser ist bereits in der Lage, Nutzeranfragen strukturiert zu verarbeiten und dabei Informationen aus internen Wissensbasen zu berücksichtigen. Trotz dieser Funktionalitäten zeigt sich in der Praxis, dass die Antworten des Chatbots überwiegend standardisiert erfolgen. Individuelle Nutzerpräferenzen werden dabei nicht sitzungsübergreifend oder über längere Konversationen hinweg von dem Chatbot beachtet.

Dieses Problem führt dazu, dass die Erwartungen an die Leistungsfähigkeit des Systems nicht vollständig erfüllt werden können. Gerade aus der Sicht des Kunden kann ein ineffizientes Chatbot-System negative Einflüsse auf die Geschäftsbeziehung oder die Wahrnehmung des Unternehmens haben. Gleichzeitig beeinträchtigt es die interne Produktivität der Mitarbeiter, da Präferenzen redundant geäußert werden müssen, wodurch der Aufwand in einzelnen Konversationen steigt.

Vor diesem Hintergrund wird deutlich, dass die langfristige Berücksichtigung von Nutzerpräferenzen sowohl aus Kunden- als auch aus Mitarbeiterperspektive von zentraler Bedeutung ist. Um dies zu gewährleisten, müssen geeignete Mechanismen entwickelt werden, die Nutzerpräferenzen automatisiert erfassen, strukturiert speichern und in zukünftige Interaktionen integrieren können.

1.2 Zielsetzung

Daher befasst sich diese Arbeit mit der Personalisierung von Chatbots im Unternehmenskontext. Ziel der Arbeit ist die Entwicklung eines Konzepts, das Nutzerpräferenzen und relevante Kontexte aus vergangenen Konversationen berücksichtigen kann, um die Personalisierung zukünftiger Interaktionen zu verbessern. Der Fokus liegt dabei insbesondere auf einem Retrieval-Augmented-Generation Ansatz, der im Rahmen dieser Arbeit untersucht und konzeptionell ausgearbeitet werden soll. Die Zentrale Forschungsfrage dieser Untersuchung lautet:

1.3 Abgrenzung

Ziel dieser Arbeit ist es nicht einen vollständig Personalisierten Chatbot zu entwickeln, der implizites Verhalten der Nutzer analysiert und daraus Präferenzen ableitet. Diese Ausarbeitung fokussiert sich lediglich auf Explizite Aussagen, die innerhalb von Konversationen von Nutzern getätigt wurden.

1.4 Vorgehensweise

Im ersten Teil der Arbeit werden die theoretischen Grundlagen dargestellt. In diesem Teil der Arbeit soll vor allem ein grundlegendes Verständnis für wichtige Bestandteile moderner Chatbot Architekturen wie beispielsweise Agenten, Large Language Models und Vektordatenbanken geschaffen werden, sodass Design Entscheidungen hinsichtlich der Zielsetzung nachvollziehbar sind. Gleichzeitig wird genauer erläutert welche Arten von Nutzerpräferenzen im Rahmen dieser Arbeit berücksichtigt werden. Darauf aufbauend wird der aktuelle Stand der Forschung untersucht. Dabei liegt der Fokus insbesondere auf bestehenden Ansätzen, die für die Personalisierung von Chatbots existieren.

Im anschließenden Praxisteil wird der Bezug zur betrieblichen Problemstellung bei Phoenix Contact hergestellt. Dazu wird zunächst der aktuelle Entwicklungsstand des eingesetzten Chatbots analysiert, um bestehende Prozessabläufe sowie mögliche Schwachstellen zu identifizieren

2 Theoretische Grundlagen

2.1 Large Language Models

2.1.1 Definition und Hintergrund

Large Language Models (LLMs) haben sich in den letzten Jahren zu einem bedeutenden Forschungsbereich der generativen künstlichen Intelligenz und des Natural Language Processings entwickelt. Der Begriff Large Language Modell bedeutet übersetzt so viel wie großes Sprachmodell und beschreibt allgemein ein System, das in der Lage ist natürliche Sprache zu verarbeiten und zu generieren.

Das heutige Verständnis von LLMs ist dabei eng mit der sogenannten Transformer-Architektur verbunden, die 2017 durch Vaswani et al. in der Arbeit Attention Is All You Need vorgestellt wurde und den Bereich des NLP revolutioniert hat. Der Hintergrund dieser Arbeit war es die Limitationen von rekurrenten neuronalen Netzen zu adressieren. Aufgrund einer sequenziellen Verarbeitung von Textsequenzen, konnten sie Abhängigkeiten zwischen weit auseinanderliegenden Wörtern nur eingeschränkt berücksichtigen, da Informationen über lange Sequenzen immer weiter verloren gingen.

Vaswani et al. stellen in ihrer Arbeit mit dem sogenannten Self-Attention-Mechanismus eine Lösung für dieses Problem vor. Self Attention erlaubt es dem Modell die Beziehung von einem Wort zu jedem anderen Wort im Kontext parallel zu erfassen, wodurch es lernt welche Wörter für das Verständnis eines bestimmten Wortes besonders wichtig sind. Dadurch können Kontextinformationen und semantische Beziehungen auch über längere Textsequenzen hinweg berücksichtigt werden, ohne dass diese verloren gehen.

2.1.2 Funktionsweise

Neuronale Netze bilden die technische Grundlage von LLMs und sind an der Funktionsweise biologischer Gehirne angelehnt. Sie bestehen aus einer großen Anzahl künstlicher Neuronen, die über sogenannte Gewichte miteinander verbunden sind und in mehreren Schichten organisiert werden. Während des Trainings werden diese Gewichte kontinuierlich angepasst, sodass das Modell relevante Muster in den Daten erlernen kann. Auf dieser Grundlage wird die interne Struktur des Netzwerks iterativ optimiert, um

möglichst präzise Vorhersagen treffen zu können. Aufgrund dieser Eigenschaften eignen sich neuronale Netze insbesondere für komplexe Klassifikations- und Vorhersageaufgaben.

Die Grundlegende Funktionsweise eines LLMs besteht somit darin, ein Neuronales Netz anhand einer Sequenz von sogenannten Token die nachfolgenden Token der Sequenz vorhersagen zu lassen. Token können in diesem Zusammenhang ganze Wörter, Wortteile oder Zeichen darstellen. Das Ergebnis des Prozesses ist dabei vollständig davon abhängig, wie das Neuronale Netz seine Gewichte innerhalb des Training angepasst hat.

2.1.3 Fähigkeiten und Limitierungen

LLMs weisen in diesem Zusammenhang unterschiedliche Fähigkeiten auf, wie das Generieren von zusammenhängenden Texten, das logische Schlussfolgern oder die Verarbeitung von Kontext über längere Textsequenzen hinweg. Darüber hinaus werden in der Literatur oftmals emergente Fähigkeiten beschrieben, die das Modell unbeabsichtigt erlernt, ohne dass es gezielt darauf trainiert wurde.

Es ist jedoch wichtig zu erwähnen, dass es sich bei LLMs um kein echtes Verständnis von Menschlicher Sprache oder Wissen handelt, sondern lediglich um probabilistische Vorhersagen, welches Token am wahrscheinlichsten zu einer gegebenen Sequenz an Token passt. Dadurch ist das Ergebnis grundsätzlich davon Abhängig, wie das LLM die interne Struktur an statistische Muster in den Trainingsdaten angepasst hat.

Aus diesem Grund kann es vorkommen, dass inhaltlich falsche oder frei erfundene Informationen erzeugt werden. Dieses Phänomen wird als Halluzination bezeichnet und stellt eine Grundlegende Herausforderung von LLMs dar. Halluzinationen entstehen insbesondere dann, wenn dem Modell relevante Kontextinformationen fehlen oder statistische Muster aus den Trainingsdaten zu fehlerhaften Schlussfolgerungen führen.

2.1.4 Prompting und Kontextverarbeitung

Wie das vorherige Kapitel bereits erläutert hat spielt der Kontext in LLMs eine wichtige Rolle. Dieser Kontext wird ihnen über sogenannte Prompts übermittelt. Der Begriff

Prompt bedeutet „Aufforderung“ oder „Eingabe“ und beschreibt die textuelle Anweisung, die einem LLM übergeben wird, um eine bestimmte Ausgabe zu erzeugen. Prompts können dabei sowohl einfache Fragen als auch komplexe Anweisungen, Rollenbeschreibungen oder zusätzliche Kontextinformationen enthalten. Die Qualität und Struktur eines Prompts hat einen erheblichen Einfluss auf die Qualität der generierten Antworten.

Im Kontext moderner LLMs wird häufig zwischen verschiedenen Arten von Prompts unterschieden. System-Prompts definieren grundlegende Verhaltensregeln oder Rollen des Modells, beispielsweise die Rolle eines Kundenservice-Chatbots. User-Prompts hingegen enthalten die eigentliche Eingabe des Nutzers. Darüber hinaus können zusätzliche Kontextinformationen bereitgestellt werden, etwa Dokumente, Gesprächsverläufe oder nutzerspezifische Informationen.

Die gezielte Gestaltung solcher Eingaben wird als Prompt Engineering bezeichnet. Ziel des Prompt Engineerings ist es, durch eine geeignete Formulierung der Eingaben die Qualität, Konsistenz und Relevanz der generierten Antworten zu verbessern. Insbesondere im Unternehmenskontext spielt Prompt Engineering eine wichtige Rolle, da dadurch das Verhalten eines Chatbots gezielt an bestimmte Anwendungsfälle angepasst werden kann.

Eine zentrale Herausforderung bei der Kontextverarbeitung von LLMs stellt das sogenannte Kontextfenster dar. Dieses beschreibt die maximale Anzahl an Tokens, die ein Modell gleichzeitig verarbeiten kann. Sämtliche Informationen innerhalb dieses Fensters können vom Modell bei der Generierung einer Antwort berücksichtigt werden. Wird die maximale Größe überschritten, gehen ältere Informationen verloren oder müssen entfernt werden.

Die Größe des Kontextfensters ist insbesondere für dialogbasierte Systeme relevant, da längere Konversationen dazu führen können, dass frühere Informationen nicht mehr berücksichtigt werden können. Dies stellt vor allem für personalisierte Chatbots eine Herausforderung dar, da Nutzerpräferenzen und frühere Interaktionen häufig über längere Zeiträume hinweg relevant bleiben.

2.1.5 Nutzung über APIs

In der Softwareentwicklung werden LLMs überwiegend nicht lokal betrieben sondern über Application Programming Interfaces (APIs) von externen Anbietern eingebunden. Bekannte Unternehmen, wie Anthropic, OpenAi, Google oder Meta, bieten heute Modelle mit unterschiedlichen Größen an, wodurch sie ohne großen Aufwand integriert werden können. Dieser Umstand eröffnet Unternehmen zahlreiche Möglichkeiten LLMs effizient im Betrieb einzusetzen.

Die Nutzung über APIs

2.2 Chatbots im Unternehmenskontext

2.2.1 Definition und Hintergrund von Chatbots

2.2.2 Retrieval Augmented Generation


LLMs haben die Einschränkung, dass ihre Informationen auf den Trainingsdaten basieren. Daher können sie aktuelles Wissen oder Domänenspezifisches Wissen in der Antwortgenerierung nicht gezielt einbinden und neigen daher zur Halluzination. Retrieval Augmented Generation (RAG) ist ein Framework, welches es dem Anwender ermöglicht LLMs mit externen Wissensbasen zu erweitern. Dabei werden zur Laufzeit der Prompt Erstellung zusätzliche Daten aus Datenbanken abgefragt und dem Kontext angehängen. RAG hilft dabei die Einschränkungen von LLMs zu überwinden und die Antwortgenerierung zu optimieren.

Ein typischer RAG Prozess kann der Abbildung 1 entnommen werden. Der Prozess startet mit dem Nutzer, der einen Prompt formuliert. Im Anschluss wird mithilfe des Prompts eine Query vorbereitet. Ein wichtiger Zwischenschritt in dem Prozess ist das Indexing. Beim Indexing werden Inhalte in sogenannte Chunks eingeteilt. Aus den Chunks werden mithilfe von Embedding Modellen Vektorrepräsentationen erzeugt. Das Embedding Modell sorgt dafür, dass aus semantisch ähnlichen Inhalten, ähnliche Vektorrepräsentationen erzeugt werden. Die Ähnlichkeit wird durch Metriken wie der euklidischen Distanz oder dem Skalarprodukt gemessen. Diese Vektoren werden Anschließend in Vektordatenbanken gespeichert.

Unter dem Begriff Vektordatenbank versteht man ein Datenbanksystem, welches die effiziente Speicherung, Indexierung und semantische Suche hochdimensionaler Vektoren unterstützt. Im Gegensatz zu klassischen relationalen Datenbanken sind Vektordatenbanken darauf spezialisiert semantische Suchverfahren nach inhaltlich ähnlichen Inhalten bereitzustellen. Die Suche basiert meist auf approximativen Verfahren zur Bestimmung der nächsten Nachbarn eines Query-Vektors, wodurch selbst in großen Datenmengen eine effiziente Suche gewährleistet werden kann.

Bevor der Prompt dem LLM zur Antwortgenerierung übergeben wird, wird die query geindext und es wird in der Datenbank nach ähnlichen Chunks gesucht, die für den Kontext relevant sein könnten. Diese werden anschließend mit dem Prompt kombiniert und zusammen an das LLM übertragen. Dieser Prozess führt dazu, dass Fragen besser verarbeitet werden und zusätzliche Informationen bereitgestellt werden.

Abbildung 1: Typischer RAG Prozess



Quelle: Gao et al., 2023

2.3 Forschungsansatz und Methodik

2.3.1 Design Science Research

Der wissenschaftliche Forschungsansatz Design Science Research, stellt die Auseinandersetzung mit Artefakten in den Mittelpunkt und ist für diese Arbeit geeignet. Bei der Design Science Research geht es primär darum Probleme, die in einem bestimmten praxisbezogenen Kontext bestehen, strukturiert zu bearbeiten. Das Ziel ist es, eine Verbesserung in dem Problemkontext zu erreichen, indem sich der Forscher mit der Interaktion zwischen Problemkontext und dem Artefakt auseinandersetzt. Hierzu entwickelt der Forscher sogenannte Artefakte. Im Fokus steht dabei nicht das Gestalten völlig neuer Artefakte oder einer Invention. Vielmehr geht es bei der DSR darum das erstellte Artefakt am Ende der Durchführung hinsichtlich seiner Wirksamkeit in Bezug auf das adressierte Problem zu evaluieren.

Artefakte spielen im Bereich der DSR eine zentrale Rolle. Knut Linke beschreibt ein Artefakt als eine „[...] vom Menschen geschaffene Lösung für ein konkretes, praxisbezogenes Problem [...]“ (Linke, 2026) und erläutert, dass allein die Entwicklung und Weiterentwicklung von etwas bereits ein Artefakt darstellen kann. In der Praxis kann es sich dabei konkret um Modelle, Konzepte, Softwarearchitekturen oder Prototypen handeln. Allerdings besteht die Anforderung, dass das Artefakt evaluierbar sein muss und vom Forscher problemorientiert untersucht werden kann.

Der Prozess der DSR teilt sich in mehrere Aktivitäten auf, die bei der Durchführung beachtet werden müssen. Diese Arbeit orientiert sich an dem Modell nach Peffers, welches der Abbildung 2 entnommen werden kann.


Der Prozess beginnt mit der Problem Identifikation und Motivation. Hier sollte der Forscher das Problem genau beschreiben und die Rahmenbedingungen für das Projekt erläutern. Dabei sollte sowohl aus Empirischer als auch aus Sicht der Praxis eine Relevanz für das Projekt begründet werden. In dieser Phase sollten vor allem Forschungsfragen festgelegt werden, die durch die Durchführung beantwortet werden sollen. Im Anschluss daran müssen aus der Problemstellung die konkreten Ziele abgeleitet werden.

Der nächste Schritt ist es das Artefakt zu erstellen und zu entwickeln. In dieser Phase werden wichtige Design Entscheidungen für das Artefakt getroffen.

Sobald das Artefakt erstellt wurde, muss demonstriert werden, dass es das Problem tatsächlich lösen kann. Es ist also ein Prove of Concept notwendig.

Im letzten Schritt wird die Lösung vor dem Hintergrund des Problemraums und der Zielsetzung evaluiert. Hierzu werden wissenschaftliche Methoden verwendet um die Validität der Lösung empirisch bewerten zu können. Sollte die Evaluation ergeben, dass das Artefakt das Problem und die Ziele nicht lösen kann, ist es notwendig zurück in die Design Phase zu wechseln und den Prozess erneut zu iterieren.

Abbildung 2: Design Science Research Method (DSRM) Prozess Modell



2.3.2 Methodik

3 Stand der Forschung

Die Personalisierung von Chatbots stellt gerade im Unternehmenskontext eine aktuelle Herausforderung dar. Ziel dieses Abschnittes ist es in diesem Zusammenhang aktuelle Techniken und Ansätze aus der Forschung vorzustellen, die sich ebenfalls mit dieser Fragestellung auseinandergesetzt haben.

3.1 Personalisierte LLMs

Ein oft behandeltes Thema bilden personalisierte LLMs. Dabei geht es darum LLMs explizit auf die Präferenzen eines Nutzers abzustimmen, sodass diese antworten generieren, die direkt auf eine Person zugeschnitten sind. In der Praxis stellt dies jedoch eine grundlegende Schwierigkeit für Unternehmen dar, da moderne LLMs meist in den Händen der Anbieter sind und sich nicht einfach so neu trainieren lassen. Aus diesem Grund bildet dieser Ansatz, sofern nicht eigene LLMs aufgebaut werden, einen unrealistischen Ansatz für diese Arbeit.

3.2 Chat Historie

Ein weiterer Ansatz der in vielen Arbeiten erwähnt wird, ist es die Chat Historie als Kontext in den Prompt zu integrieren. Das LLM könnte in diesem Zusammenhang selbst, die Präferenzen aus der Chat Historie extrahieren und anhand dieser eine Antwort generieren. In Anbetracht der Größe des Kontextfensters für LLMs, zeigen sich dabei jedoch grundlegende Herausforderungen, da die Anzahl an Tokens begrenzt ist.

3.3 RAG Ansätze

Im Jahr 2025 stellten Zhao et al. in ihrem wissenschaftlichen Paper "Do LLMs Recognize Your Preferences? Evaluating Personalized Preference Following in LLMs" einen Benchmark (PrefEval) zur Evaluation der Präferenzverarbeitung in konversationsbasierten LLM-Systemen vor. In dieser Arbeit wurde untersucht, wie gut LLM Modelle Nutzerpräferenzen über längere Konversationen hinweg erkennen, speichern und in Antworten berücksichtigen können.

Die Ergebnisse des Benchmarks zeigen, dass moderne LLMs grundsätzlich in der Lage sind, Nutzerpräferenzen innerhalb von Konversationen zu berücksichtigen. Gleichzeitig zeigt sich jedoch, dass insbesondere die konsistente Verarbeitung von Präferenzen über längere und mehrere Konversationen hinweg weiterhin eine zentrale Herausforderung darstellt.

Die Ergebnisse des Benchmarks zeigen, dass die Fähigkeit von LLMs zur Berücksichtigung von Nutzerpräferenzen mit zunehmender Gesprächslänge deutlich abnimmt. Während Präferenzen in kurzen Konversationen häufig noch korrekt verarbeitet werden können, sinkt die Genauigkeit bei längeren Dialogen erheblich. Insbesondere Präferenzen, die früh innerhalb einer Konversation genannt wurden, werden von den Modellen häufig nicht mehr zuverlässig berücksichtigt.

Die Ergebnisse von PREFEVAL zeigen jedoch auch, dass insbesondere RAG-basierte Ansätze Halluzinationen reduzieren und die konsistente Berücksichtigung von Nutzerpräferenzen verbessern können. Durch den gezielten Abruf relevanter Präferenzinformationen aus externen Speicherstrukturen gelingt es den Modellen besser, frühere Nutzerangaben in späteren Konversationen erneut zu berücksichtigen. Dies ist insbesondere für personalisierte Chatbots im Unternehmenskontext relevant, da Nutzerpräferenzen häufig über längere Zeiträume hinweg konsistent verarbeitet werden müssen.

Externe Retrieval-Mechanismen bilden somit einen vielversprechenden Ansatz, um die Limitierungen kontextbasierter Präferenzverarbeitung moderner LLMs zu adressieren.

4 Praxisteil

4.1 Vorstellung des Praxisunternehmens

Phoenix Contact ist ein global tätiges Familienunternehmen, das sich mit dem strategischen Ziel zur Umsetzung der „All Electric Society“ in der Elektroindustrie positioniert. Die Produkte von Phoenix Contact bieten unterschiedliche Lösungen für die Bereiche Automatisierung, Vernetzung und Elektrifizierung. Diese Arbeit wurde in der Abteilung "Data Science & Engineering - Generative AI" (DSE GenAi) verfasst, die ein Teil der Muttergesellschaft Phoenix Contact GmbH & Co.KG ist.

Die Abteilung DSE GenAi setzt sich wie der Name bereits verrät, für Lösungen im Bereich der Generativen Künstlichen Intelligenz ein. Diese Lösungen werden ausschließlich innerhalb des Unternehmens eingesetzt und verfolgen die Absicht verschiedenste Prozesse mithilfe Intelligenter Assistenten zu unterstützen. In diesem Rahmen sind in der Vergangenheit beispielsweise Projekte wie ein Enterprise-Chatbot, ein Coding Assistent und ein Techbot entstanden.

Der Enterprise Chatbot namens "Phoenix Contact Intelligent Assistant" (PIA) spielt für diese Arbeit eine Zentrale Rolle. Es handelt sich dabei um einen Chatbot, der mit Unternehmensdaten erweitert wurde und dadurch präzisere Antworten über Phoenix Contact bereitstellen kann. Da sich die Umwelt im Bereich der künstlichen Intelligenz stetig weiterentwickelt, neue KI Modelle veröffentlicht werden und die Erwartungen der Nutzer zunehmend steigen, ist es auch Zukünftig wichtig, dass vorhandene Projekte wie der Enterprise Chatbot von der Abteilung evaluiert und weiterentwickelt werden.

4.2 Ist-Analyse

Da der Enterprise Chatbot PIA die Grundlage für diese Arbeit darstellt, ist es sinnvoll zunächst zu analysieren auf welchen Technologischen Stand sich dieser bereits befindet. Dieser Abschnitt konzentriert sich dabei auf die Architektur, die zum näheren Verständnis in der Abbildung 3 illustriert wird.

Insgesamt unterteilt sich die Architektur in eine Präsentations- und Orchestrierungsschicht. Die Präsentationsschicht basiert hauptsächlich auf einem React Frontend, worüber Authentifizierte Nutzer die Möglichkeit haben eigene Chats zu starten und Anfragen zu formulieren. Hierbei entscheidet der Nutzer selbst, ob eine interne Wissensbasis für die Antwortgenerierung genutzt werden soll.

Die Kommunikation zwischen Frontend und Orchestrierungsschicht erfolgt über FastAPI-Schnittstellen. Sobald ein Prompt durch den Nutzer abgeschickt wird, wird innerhalb der Orchestrierungsschicht eine Verarbeitungspipeline ausgelöst. Der erste Schritt dieser Pipeline ist eine Routing Function, welche bestimmt, ob eine Anfrage direkt durch ein Sprachmodell beantwortet werden kann oder ob zusätzlich internes Wissen benötigt wird. Falls keine interne Wissensbasis erforderlich ist, wird die Anfrage unmittelbar an Azure OpenAI Services weitergeleitet.

Wird hingegen internes Wissen benötigt, startet eine mehrstufige RAG-Pipeline. Zunächst erfolgt eine Transformation der Benutzeranfrage, um die Suchanfrage für nachfolgende Retrieval-Prozesse zu optimieren. Anschließend wird mithilfe von FastText die Sprache der Anfrage identifiziert. Da das System mehrsprachig ausgelegt ist, ist zusätzlich eine Übersetzung der Anfrage in Deutsch oder Englisch vorhergesehen.


Die eigentliche Informationssuche basiert auf einem hybriden Suchansatz. Hierbei werden klassische schlüsselwortbasierte Suchverfahren mit semantischer Vektorsuche kombiniert. Die Suche wird über Azure AI Search realisiert und anschließend durch ein Reranking ergänzt, um besonders relevante Dokumente höher zu priorisieren. Die Ergebnisse verschiedener Suchprozesse werden danach zusammengeführt und anhand eines Similarity Thresholds gefiltert, sodass nur ausreichend relevante Inhalte berücksichtigt werden.

Im Anschluss erfolgt das sogenannte Context Filling, bei dem die gefundenen Dokumente in den Kontext der Anfrage integriert werden. Auf Basis dieses erweiterten Kontextes wird schließlich mithilfe von Azure OpenAI Services eine Antwort generiert und an das Frontend zurückgegeben.

Neben der eigentlichen Anfrageverarbeitung beinhaltet die Architektur zusätzlich eine Observability-Schicht. Diese dient der Überwachung und Analyse des Systems. Hierfür kommen unter anderem Langfuse zur Nachverfolgung von Prompts und Modellantworten, Azure Blob Storage zur Datenspeicherung, Snowflake zur Analyse strukturierter

Daten sowie Tempo und Grafana zur Visualisierung und Überwachung von Systemmetriken zum Einsatz.

Abbildung 3: PIA Architektur



4.3 Identifikation des Problemraums

Aus der zugrunde liegenden Problemstellung dieser Arbeit geht hervor, dass der betrachtete Chatbot bislang keine Funktionen zur Personalisierung von Nutzeranfragen bereitstellt. Die resultierende Einschränkung des Systems lässt sich im Kern auf zwei zentrale Defizite zurückführen:

- Die Unfähigkeit, vergangene Konversationen bei der Verarbeitung aktueller Anfragen zu berücksichtigen
- Die fehlende Erfassung sowie Nutzung individueller Nutzerpräferenzen

Für die zielgerichtete Entwicklung eines geeigneten Artefakts ist ein vertieftes Verständnis des Problemraums unerlässlich. Neben der reinen Beschreibung der bestehenden Defizite ist es notwendig, die zugrunde liegenden Schwächen des aktuellen Systems sowie die relevanten Rahmenbedingungen systematisch zu analysieren. Aufbauend auf dieser Analyse erfolgt im weiteren Verlauf die Ableitung konkreter Zielsetzungen für das zu entwickelnde Artefakt.

4.3.1 Schwächenanalyse

Der derzeitige technische Stand des betrachteten Chatbots offenbart im Hinblick auf die identifizierte Problemstellung eine grundlegende strukturelle Schwäche. Eingehende Nutzeranfragen werden aktuell isoliert und sequenziell verarbeitet, ohne dabei Informationen aus vorherigen Interaktionen zu berücksichtigen.

Zwar werden Konversationsdaten bereits zu Zwecken der Observability in einer Datenbank persistiert, jedoch erfolgt keine weiterführende Nutzung dieser Daten im Sinne einer semantischen Wiederverwendung. Insbesondere fehlt ein Mechanismus zur gezielten Erschließung und Integration historischer Konversationsinhalte in zukünftige Interaktionen.

Folglich existiert kein vorgelagerter Prozess, der vor der eigentlichen Anfrageverarbeitung relevante Informationen—wie etwa Nutzerpräferenzen oder kontextspezifische Hinweise—aus der Datenbasis extrahiert und in die Eingabestruktur (Prompt) des Sprachmodells integriert. Diese fehlende Kontextanreicherung führt dazu, dass der Chatbot wiederholt Rückfragen stellen muss oder generische Antworten liefert, obwohl

relevante Informationen aus vorangegangenen Interaktionen prinzipiell verfügbar wären.

Zusammenfassend lässt sich festhalten, dass die zentrale Schwäche des Systems nicht in der Datenerfassung, sondern in der fehlenden semantischen Erschließung und Nutzung dieser Daten liegt.

4.3.2 Rahmenbedingungen

Die Entwicklung des Artefakts erfolgt unter Berücksichtigung technischer und organisatorischer Rahmenbedingungen, die maßgeblichen Einfluss auf die Gestaltung der Lösung haben.

Zum einen ist das verfügbare Budget begrenzt und bewegt sich im Bereich von ... bis Dies impliziert, dass sowohl Implementierungs- als auch Betriebskosten, insbesondere im Hinblick auf externe Dienste (z. B. Embedding-Modelle oder Vektordatenbanken), sorgfältig abgewogen werden müssen.

Zum anderen ist eine enge Anbindung an die bestehende Systemarchitektur erforderlich. Das zu entwickelnde Artefakt sollte daher möglichst modular gestaltet sein und sich mit geringem Eingriff in die bestehende Infrastruktur integrieren lassen. Eine vollständige Neugestaltung des Systems ist nicht vorgesehen.

Darüber hinaus muss die Lösung mit den vorhandenen Datenstrukturen kompatibel sein und bestehende Persistenzmechanismen sinnvoll erweitern, ohne deren Stabilität oder Performance negativ zu beeinflussen.

4.3.3 Ziele

Basierend auf der zuvor durchgeführten Analyse des Problemraums lassen sich folgende zentrale Zielsetzungen für das zu entwickelnde Artefakt ableiten:

- Entwicklung eines Mechanismus zur semantischen Erschließung von Konversationsdaten, insbesondere durch die Transformation von Textinhalten in Vektorrepräsentationen

- Implementierung einer Vektordatenbank zur effizienten Speicherung und Abfrage semantisch ähnlicher Konversationsabschnitte
- Realisierung eines Retrieval-Ansatzes, der relevante historische Informationen kontextabhängig identifiziert und bereitstellt
- Integration der gewonnenen Kontextinformationen in den Anfrageverarbeitungsprozess zur Verbesserung der Antwortqualität
- Ermöglichung der automatisierten Erkennung und Berücksichtigung von Nutzerpräferenzen in zukünftigen Interaktionen
- Sicherstellung einer nahtlosen Integration in die bestehende Systemlandschaft unter Berücksichtigung der definierten Rahmenbedingungen

Ziel des Artefakts ist es somit, die bestehende statische und kontextunabhängige Verarbeitung von Nutzeranfragen durch eine dynamische, kontextbasierte und personalisierte Interaktion zu erweitern.

5 Evaluation


Anhang

Anhangsverzeichnis

Anhang 1:	Alte Schaltlogik	21
Anhang 2:	Testergebnisse	21
Anhang 2.1:	Variablen nach einlesen der XML-Datei	21
Anhang 2.2:	Ergebnisse des Zeitvergleiches	21

Anhang 1 Alte Schaltlogik


Abbildung 4: Aktuelle Schaltlogik des Funktionsbausteins



Anhang 2 Testergebnisse


Anhang 2.1 Variablen nach einlesen der XML-Datei

Abbildung 5: Ansicht im Anlagen Ordner



Anhang 2.2 Ergebnisse des Zeitvergleiches

Abbildung 6: Ergebnisse des Zeitvergleiches



Quellenverzeichnis

Monographien

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Guo, Q., Wang, M.,
& Wang, H. (2023). Retrieval-Augmented Generation for Large Language Models:
A Survey. <https://api.semanticscholar.org/CorpusID:266359151>

Ehrenwörtliche Erklärung

Hiermit erkläre ich, dass ich die vorliegende Bachelorthesis selbständig angefertigt habe. Es wurden nur die in der Arbeit ausdrücklich benannten Quellen und Hilfsmittel benutzt. Wörtlich oder sinngemäß übernommenes Gedankengut habe ich als solches kenntlich gemacht. Diese Arbeit hat in gleicher oder ähnlicher Form noch keiner Prüfungsbehörde vorgelegen.

Paderborn, 2. Juni 2026

Fabio Mirabile