



Evolution im Dialog: Vom Chatbot zur Conversational AI

Ein praxisorientierter Leitfaden zu LLM-Architektur, Strategie und verantwortungsvoller Implementierung von KI-Assistenten

Julia Lehmann

Inhalt

1	Einleitung	362
2	Die KI-Revolution im Messaging: Der neue Katalysator für Conversational AI	363
3	Wie Unternehmen von Conversational AI profitieren können	363
4	Wie Maschinen menschenähnliche Konversationen führen: Die LLM-Revolution	365
5	Vom Chatbot-Konzept zur praktischen Umsetzung: State of the Art 2025	369
6	Wie Conversational AI funktioniert: LLMs, Herausforderungen und Integrationen	374
7	Tool-Evaluierung	378
8	Fazit und Ausblick: Die Ära der intelligenten KI-Agenten und Mensch-Maschine-Kollaboration	382
	Literatur	384

Zusammenfassung

Die Landschaft der Chatbots hat sich fundamental gewandelt: Moderne Conversational AI, basierend auf Large Language Models (LLMs), ist heute ein strategischer Hebel für exzellente Customer Experience und operative Effizienz in Unternehmen. Dieser Beitrag erklärt praxisnah die Funktionsweise dieser neuen KI-Systeme, ihre erweiterten Einsatzmöglichkeiten von der Hyperpersonalisierung bis zur Generierung tiefer Customer Insights und den daraus resultierenden Mehrwert. Er bietet Entscheidern konkrete Ratschläge für die Entwicklung eines LLM-spezifischen Konzepts – von der Strategie über Prompt Engineering und Retrieval-Augmented Generation (RAG) bis zur Tool-Auswahl. Zentrale Herausforderungen wie Halluzinationen, Datenschutz und Bias werden ebenso beleuchtet.

Zur besseren Lesbarkeit wird in diesem Beitrag das generische Maskulinum verwendet. Die verwendeten Personenbezeichnungen beziehen sich – sofern nicht anders kenntlich gemacht – auf alle Geschlechter.

J. Lehmann (✉)

Onfore/Digital Business Institute an der HfWU, Nürtingen, Deutschland

E-Mail: julia@onfore.com

tet wie Lösungsansätze für eine erfolgreiche und verantwortungsvolle Implementierung von KI-basierten virtuellen Assistenten.

Schlüsselwörter

Conversational-AI-Strategie · Retrieval-Augmented Generation (RAG) · Responsible AI · Implementierung von KI-Assistenten · Large Language Model (LLM)

1 Einleitung

Mit der fortschreitenden Digitalisierung und der Allgegenwart von künstlicher Intelligenz (KI) steigen auch die Erwartungen auf Kundenseite exponentiell: Sie wünschen nicht nur 24/7-Verfügbarkeit über alle Kanäle und schnellen Service, sondern erwarten auch proaktive, hyperpersonalisierte Interaktionen statt generischer Massenangebote. Kunden erwarten zunehmend sofortige Unterstützung, unabhängig von traditionellen Geschäftszeiten. Die exzellente „Customer Experience“ ist im Jahr 2025 nicht nur ein grundlegendes Erfordernis, sondern ein entscheidender Differenzierungsfaktor geworden, der maßgeblich die Kundenloyalität beeinflusst (Huang et al., 2024) und über die Wettbewerbsfähigkeit von Unternehmen entscheidet (vgl. Mökander et al., 2023, zur Bedeutung von Ethik in KI-Entscheidungen). Die durch KI ermöglichte Hyperpersonalisierung hat die Kundenerwartungen nochmals erheblich gesteigert (Winkler et al., 2023).

Doch was verbirgt sich hinter einem modernen Chatbot im Jahr 2025? Es sind fortgeschrittene KI-Systeme, oft basierend auf Large Language Models (LLMs), die durch kontextuelles Verständnis und dynamische Anpassungsfähigkeit überzeugen. Sie können nicht nur Hunderte von Fragestellungen verstehen und beantworten, sondern bieten zunehmend personalisierte Unterstützung, die sich kontinuierlich an Nutzerinteraktionen anpasst (vgl. Jegan & Akilandeswari, 2023). Einfach gesagt ist ein Chatbot, auch bekannt als Conversational Bot oder Conversational Artificial Intelligence (AI), ein lernfähiges Computerprogramm, das so konzipiert ist, dass es menschliche Konversation simuliert, Aufgaben automatisiert und über eine Konversationsschnittstelle mittels Text oder Stimme kommuniziert (adaptiert von Zumstein & Hundertmark, 2017, S. 98).

Die Vorteile moderner KI-Chatbots gehen weit über die 24/7-Verfügbarkeit und initiale Kosteneinsparungen hinaus. Sie ermöglichen ein tiefgehend personalisiertes Kundenerlebnis und haben das Potenzial, die Kundenbindung zu fördern. Gleichzeitig bleibt die Optimierung der Servicekosten ein wesentlicher Faktor. Jedoch bestehen weiterhin Herausforderungen, etwa im Umgang mit sprachlichen Mehrdeutigkeiten sowie ethische Bedenken hinsichtlich Datenschutz und möglicher algorithmischer Verzerrungen. Zudem spielt der Einsatz von Chatbots eine zentrale Rolle in der digitalen Transformation von Unternehmen und wird zunehmend auch mit Nachhaltigkeitsaspekten verknüpft (van Straelen & Schleuss, 2023).

Dieser Beitrag beschreibt, wie KI-basierte virtuelle Assistenten funktionieren, welche Einsatzgebiete es gibt und welcher Mehrwert erwartet werden kann. Er gibt Ratschläge für die Gestaltung eines schlüssigen Conversational-AI-Konzepts und weist auf mögliche Stolperfallen bei der Umsetzung hin. So entsteht ein praktischer Guide von der Chatbot-Idee bis hin zur erfolgreichen Entwicklung von KI-basierten virtuellen Assistenten.

2 Die KI-Revolution im Messaging: Der neue Katalysator für Conversational AI

Das Smartphone gilt als das zentrale Kommunikationsmedium unserer Zeit, doch die Landschaft hat sich seit der ursprünglichen „Messaging-Revolution“ grundlegend gewandelt. Messaging-Plattformen wie WhatsApp (mit über 2 Mrd. Nutzern, Stand Februar 2025), WeChat (1,38 Mrd. Nutzer) und Facebook Messenger (947 Mio. Nutzer) sind nicht mehr nur Kanäle – sie sind etablierte Ökosysteme für private und geschäftliche Interaktionen geworden (Statista, 2025). Während die anfängliche Verlagerung der Kommunikation hin zu Messaging-Diensten den Nährboden bereitete, ist der wahre Katalysator für die heutige und zukünftige Bedeutung von Chatbots die Integration hoch entwickelter KI, insbesondere von Large Language Models (LLMs), in diese Plattformen.

Die Präferenz der Kunden, Serviceanfragen bequem über Messaging zu stellen, statt in Warteschleifen zu verharren oder umständliche Webseiten zu navigieren, ist ungebrochen (vgl. Twilio, 2020). Bereits heute interagieren über 1,4 Mrd. Menschen aktiv mit Chatbots auf Messaging-Plattformen, und diese machen etwa 39 % aller Chats zwischen Unternehmen und Kunden aus (Masterofcode.com, 2024). Was sich jedoch geändert hat, ist die Erwartungshaltung: Nutzer erwarten nicht mehr nur einfache, automatisierte Antworten, sondern zunehmend intelligente, kontextsensitive und menschenähnliche Dialoge.

Hier setzt die transformative Kraft moderner Conversational AI an. Systeme, die auf LLMs basieren, ermöglichen es, komplexe Anfragen zu verstehen, nuancierte Antworten zu generieren und Aufgaben autonomer zu erledigen. Sie können bis zu 80 % der Routineaufgaben im Kundenservice automatisieren und Antwortzeiten erheblich verkürzen (Masterofcode.com, 2024).

3 Wie Unternehmen von Conversational AI profitieren können

Moderne Conversational-AI-Systeme, insbesondere solche, die auf LLMs basieren, sind weit mehr als nur schnelle und effiziente Lösungen für einfache Anfragen. Sie entwickeln sich zu leistungsstarken Werkzeugen, die komplexe Probleme lösen, personalisierte Interaktionen ermöglichen und Unternehmen über alle digitalen Kanäle hinweg ein intelligentes „Gesicht“ nach außen geben (vgl. Deloitte, 2024, zu KI als „unsichtbarer Substruktur“). Sie können dabei helfen, tiefere Kundenbe-

ziehungen aufzubauen, indem sie nicht nur informieren, sondern durch kontextuelles Verständnis und gezieltes Storytelling auch Engagement und Bindung fördern.

3.1 Der Einsatz und Mehrwert von Conversational AI in der Praxis

Die Einsatzgebiete für Conversational AI haben sich durch LLMs erheblich erweitert und vertieft. Während einfache Anwendungsfälle nach wie vor relevant sind, ermöglichen moderne Systeme komplexere und wertschöpfendere Interaktionen:

Aus Kundenperspektive:

- *Nahtlose Multi-Channel-Verfügbarkeit:* Intelligente Assistenten bieten konsistente Erlebnisse über alle Kanäle hinweg, 24/7.
- *Verbesserte Kundenerfahrung:* Schnellere, präzisere und kontextbezogene Antworten auf komplexe Fragen. Die Fähigkeit zur (simulierten) Empathie und Stimmungsanalyse kann die Interaktion menschlicher gestalten (Zhou et al., 2023).
- *Hyperpersonalisierung:* Proaktive, individuell zugeschnittene Angebote und Unterstützung basierend auf tiefem Verständnis der Kundenhistorie und -präferenzen (Winkler et al., 2023).

Aus Unternehmensperspektive:

- *Effizienzsteigerung und Kostensenkung:* Hohe Automatisierungsraten (bis zu 80 % für Routineaufgaben, Masterofcode.com, 2024, 2026) senken Servicekosten und entlasten Mitarbeiter. Unternehmen, die PricewaterhouseCoopers (PwC) als „Top Performer“ bei der Cloud- und KI-Einführung identifiziert, sehen bereits signifikante Verbesserungen bei Produktivität und Kosteneinsparungen (PwC, 2024, S. 3).
- *Umsatzsteigerung:* Verbesserte Lead-Generierung, höhere Konversionsraten durch personalisierte Verkaufsansprachen und Upselling/Cross-Selling (Masterofcode.com, 2024).
- *Mitarbeiterproduktivität und -zufriedenheit:* Entlastung von repetitiven Aufgaben ermöglicht es Mitarbeitern, sich auf komplexere, wertschöpfendere Tätigkeiten zu konzentrieren (Microsoft, 2023; PwC, 2024). KI-Tools können Mitarbeiter direkt unterstützen (z. B. Code-Generierung, Informationsbeschaffung).
- *Tiefgreifende Customer Insights:* LLMs können nuancierte Einblicke aus großen Mengen unstrukturierter Gesprächsdaten gewinnen (Stimmungen, Bedürfnisse, Trends), die zur Verbesserung von Produkten, Services und Marketingstrategien genutzt werden können. Diese Fähigkeit übertrifft traditionelle Analysemethoden.
- *Innovationsfähigkeit:* KI als Werkzeug in der Produktentwicklung und zur Identifizierung neuer Geschäftsmöglichkeiten.

- *Skalierbarkeit*: KI-Systeme können Nachfragespitzen ohne proportionale Erhöhung der Mitarbeiterzahl bewältigen (EY, 2025, S. 11–14 – „The scalability challenge“).

Durch die tiefe Integration in Backend-Systeme (CRM, ERP etc.) mittels APIs können KI-Systeme komplexe, unternehmensspezifische Aufgaben automatisieren und den Mitarbeitern als leistungsstarke Assistenten zur Seite stehen, weit über einfache FAQs oder IT-Support-Anfragen hinaus (Pereira & Díaz, 2018). Die rasante Entwicklung, insbesondere im Bereich der Agenten-KI, wird kontinuierlich neue, anspruchsvollere Anwendungsszenarien ermöglichen.

Der Mehrwert der Customer Insights sollte bei Conversational-AI-Projekten nicht unterschätzt werden. Moderne Systeme sind ideale Werkzeuge, um Kundenerwartungen auf einer tieferen Ebene zu verstehen. Über die Analyse von Konversationen lassen sich detaillierte Informationen zu Bedürfnissen, Schwachstellen und Stimmungen gewinnen, die weit über das hinausgehen, was mit einfachen Chatbots möglich war. Diese Erkenntnisse sind Gold wert für die Produktentwicklung, Serviceoptimierung und die Gestaltung zukünftiger Marketingstrategien. Eine leistungsstarke Analysefunktionalität, die die Fähigkeiten von LLMs zur Verarbeitung natürlicher Sprache nutzt, ist daher unerlässlich.

Der strategische Einsatz von Conversational AI ist zunehmend ein Zeichen von Innovations- und Wettbewerbsfähigkeit. Die Entscheidungen, die Unternehmen heute bezüglich der Integration von KI in ihre Kundeninteraktionen und Kernprozesse treffen, werden maßgeblich ihren zukünftigen Erfolg beeinflussen (EY, 2025; Deloitte, 2024).

4 Wie Maschinen menschenähnliche Konversationen führen: Die LLM-Revolution

Große Sprachmodelle (LLMs) bringen Maschinen erstmals auf ein Niveau, das echte, menschenähnliche Gespräche ermöglicht.

4.1 Die Grundlage: Transformer-Architektur und LLMs

Der technologische Durchbruch, der LLMs ermöglichte, war die Einführung der *Transformer-Architektur* im Jahr 2017 durch Vaswani et al. in ihrem wegweisenden Paper „Attention Is All You Need“. Im Gegensatz zu früheren Modellen, die Sequenzen Wort für Wort verarbeiteten (rekurrente Netze), erlaubt die Transformer-Architektur dem Modell, die Beziehungen zwischen allen Wörtern in einem Text *gleichzeitig* zu berücksichtigen. Dies geschieht durch einen Mechanismus namens „*Attention*“ (Aufmerksamkeit), der es dem Modell ermöglicht, zu lernen, welche Wörter für das Verständnis eines bestimmten Wortes im Kontext am relevantesten sind (Vaswani et al., 2017).

Basierend auf dieser Architektur wurden *Large Language Models (LLMs)* entwickelt. Dies sind neuronale Netze, die auf riesigen Mengen von Text- und Code-Daten (oft Billionen von Wörtern) vortrainiert werden. Durch diesen Prozess lernen sie statistische Muster, Grammatik, Faktenwissen und sogar Schlussfolgerungsfähigkeiten (Bommasani et al., 2022).

- *Kontextverarbeitung*: LLMs können den Kontext über lange Textabschnitte hinweg verstehen und berücksichtigen. Moderne Modelle wie GPT-4 oder O3 von OpenAI können Kontextfenster von 128.000 bis 200.000 Tokens verarbeiten (YouGPT.ai, 2025), was ihnen erlaubt, kohärente und relevante Antworten auch in komplexen Dialogen zu generieren.
- *Generative Fähigkeiten*: LLMs generieren Text, indem sie probabilistisch das wahrscheinlichste nächste Wort (oder Token) vorhersagen, basierend auf dem bisherigen Kontext. Sie können nicht nur antworten, sondern auch Texte zusammenfassen, übersetzen, kreativ schreiben oder Code generieren.
- *Emergente Fähigkeiten*: Ab einer bestimmten Größe zeigen LLMs oft Fähigkeiten, für die sie nicht explizit trainiert wurden, wie z. B. einfache Arithmetik oder logisches Schlussfolgern (Brown et al., 2020).
- *Adaptierbarkeit (Fine-Tuning/Prompting)*: LLMs können durch sog. Fine-Tuning (weiteres Training auf spezifischeren Daten) oder einfach durch geschickte Formulierung der Eingabeaufforderung (Prompting) an spezifische Aufgaben oder Domänen angepasst werden (Brown et al., 2020).

4.2 Kerntechnologien und Konzepte im LLM-Zeitalter

- *Natural Language Processing (NLP)/Understanding (NLU)*: Während NLP der Oberbegriff für die maschinelle Verarbeitung natürlicher Sprache bleibt, erreichen LLMs NLU (das Verstehen von Sprache) auf eine neue Weise. Sie lernen die Bedeutung und den Kontext von Wörtern und Sätzen implizit aus den Mustern in den Trainingsdaten, anstatt auf explizit programmierten grammatikalischen Regeln zu basieren (Bommasani et al., 2022). LLMs können Mehrdeutigkeiten oft besser auflösen und die Absicht (Intent) hinter einer Nutzeranfrage oft ohne explizite Intent-Definition erkennen.
- *Maschinelles Lernen (ML)*: LLMs sind ein Ergebnis des Deep Learning, einem Teilbereich des ML. Ihr „Lernen“ besteht darin, die Parameter (Gewichte) des neuronalen Netzes während des Pre-Trainings so anzupassen, dass sie die Struktur der Trainingsdaten optimal modellieren (z. B. das nächste Wort vorhersagen). Dieser datengetriebene Ansatz unterscheidet sich fundamental von der klassischen Programmierung, bei der Regeln explizit definiert werden (vgl. Original 1.4.2, Pandey, 2019).
- *Retrieval-Augmented Generation (RAG)*: Eine der wichtigsten Techniken für den Unternehmenseinsatz von LLMs ist RAG. Da LLMs „halluzinieren“ können (faktenfreie, aber plausibel klingende Aussagen generieren) und ihr Wissen auf dem Stand ihrer Trainingsdaten basiert, kombiniert RAG das LLM mit einer




Abb. 1 Technologien und Konzepte der LLM-Revolution

externen Wissensdatenbank (z. B. Unternehmensdokumente, Produktdatenbank) (Lewis et al., 2020). Wenn eine Anfrage eingeht, sucht das System zuerst relevante Informationen in der Datenbank (Retrieval) und gibt diese Information dann dem LLM als zusätzlichen Kontext für die Generierung der Antwort (Augmented Generation) (Chen & Kumar, 2024; SciSpace LLMs Revolution). Dies erhöht die Faktentreue und ermöglicht die Nutzung aktueller, unternehmensspezifischer Informationen.

- **Multimodalität:** Neuere LLMs wie Googles Gemini-Familie oder OpenAIs GPT-4(V/O3) sind multimodal. Sie können nicht nur Text, sondern auch Eingaben in anderen Modalitäten (Bild, Audio, z. T. Video) verarbeiten und/oder generieren (Google DeepMind, 2023; OpenAI, 2023; YouGPT.ai, 2025). Dies ermöglicht natürlichere Interaktionen und neue Anwendungsfälle, z. B. die Beschreibung eines Bildes oder die Beantwortung von Fragen zu einem Diagramm (Deloitte, 2024, S. 5).

Abb. 1 zeigt Technologien und Konzepte der LLM-Revolution.

4.3 Typen moderner Conversational-AI-Systeme

Statt der alten Einteilung (Entscheidungsbaum, Keyword, Kontext) klassifiziert man moderne Systeme eher nach den zugrundeliegenden Modellen und Architekturen:

- *Systeme basierend auf großen Foundational Models (über APIs):* Viele Unternehmen nutzen die leistungsfähigsten LLMs (z. B. GPT-4/O3, Claude 3, Gemini) über APIs von Anbietern wie OpenAI, Anthropic oder Google. Diese bieten hohe

Leistungsfähigkeit, erfordern aber eine Internetverbindung und werfen Fragen bezüglich Datenschutz und Kosten auf (McKinsey Global Institute, 2025).

- *Systeme basierend auf Open-Source-LLMs*: Modelle wie Llama (Meta), Mistral oder Gemma (Google) können selbst gehostet werden (on-premise oder in der eigenen Cloud), was mehr Kontrolle über Daten und potenziell niedrigere Betriebskosten ermöglicht (Kumar, 2024; Touvron et al., 2023; SciSpace LLMs Revolution). Sie erfordern jedoch mehr technisches Know-how für Implementierung und Betrieb.
- *Spezialisierte/Feingetunte Modelle (oft SLMs – Small Language Models)*: Für spezifische Aufgaben oder Branchen können kleinere, spezialisierte Modelle effizienter sein. Diese können entweder von Grund auf trainiert oder durch Fine-Tuning großer Modelle erstellt werden. Sie benötigen weniger Ressourcen und können z. T. sogar auf Endgeräten laufen (Deloitte, 2024, S. 5, 18).
- *Hybride Systeme*: In der Praxis kombinieren viele Lösungen verschiedene Ansätze. Ein regelbasiertes System kann einfache, hochstrukturierte Anfragen (z. B. Passwort-Reset) bearbeiten, während komplexere Dialoge an ein LLM weitergeleitet werden. Oft werden RAG-Systeme mit LLMs kombiniert (Hartmann & Weber, 2024; McKinsey Arenas Compendium, S. 11).

4.4 Wie LLMs Antworten generieren

Wenn ein LLM eine Antwort generiert, geschieht dies typischerweise Token für Token (ein Token ist oft ein Wortteil) (Baktash & Dawodi, 2023). Die Generierung verläuft sequenziell, wobei jedes einzelne Token nacheinander produziert wird (Li et al., 2024a).

Eingabe & Kontext: Die bisherige Konversation und die aktuelle Nutzereingabe werden in Tokens zerlegt und als Eingabe an das Modell gegeben (Ren, 2024). Diese Tokens dienen als Grundlage für die weitere Verarbeitung durch das LLM (Ratio et al., o. J.).

Wahrscheinlichkeitsverteilung: Das LLM berechnet für das nächste Token eine Wahrscheinlichkeitsverteilung über alle möglichen Tokens in seinem Vokabular (Baktash & Dawodi, 2023). Diese Verteilung basiert auf statistischen Modellen, die durch massives Training mit Textdaten entstanden sind (Ratio et al., o. J.).

Auswahl des nächsten Tokens: Basierend auf dieser Verteilung wird das nächste Token ausgewählt (Ren, 2024). Dies kann deterministisch (z. B. immer das wahrscheinlichste Token wählen – „greedy decoding“) oder stochastisch (zufällige Auswahl basierend auf den Wahrscheinlichkeiten, oft beeinflusst durch Parameter wie „Temperatur“) geschehen (Baktash & Dawodi, 2023). Stochastische Methoden führen zu kreativeren, aber potenziell weniger präzisen Antworten (Li et al., 2024).

Iteration: Das neu ausgewählte Token wird an den bisherigen Text angehängt, und der Prozess wiederholt sich, bis ein Stopp-Signal generiert wird (Li et al., 2024). Bei diesem iterativen Prozess werden die bereits generierten Tokens Teil des Kontexts für die Erzeugung der nächsten Tokens (Ren, 2024).

4.5 Die Bedeutung von Kontext und Gedächtnis

Die Qualität der LLM-Antworten hängt entscheidend vom bereitgestellten Kontext ab (Li et al., 2025). Das Kontextfenster (Context Window) eines LLMs bestimmt, wie viele Tokens (aus der bisherigen Konversation und der aktuellen Eingabe) das Modell bei der Generierung der nächsten Antwort berücksichtigen kann (Stallone et al., 2024).

Größere Kontextfenster (z. B. 128K bei GPT-4) ermöglichen es dem Modell, den Faden auch in längeren Dialogen nicht zu verlieren (Li et al., 2025). Moderne Modelle wie ChatQA 2 und andere auf Llama 3.0-basierende Modelle haben mittlerweile Kontextfenster von bis zu 128K Tokens erreicht, was die Verarbeitung großer Informationsmengen in einer einzigen Anfrage ermöglicht (Stallone et al., 2024).

Die effektive Verwaltung dieses Kontexts und die Simulation eines „Gedächtnisses“ über eine einzelne Konversation hinaus bleiben jedoch technische Herausforderungen (Hasegawa et al., 2024), die oft durch externe Systeme (wie Datenbanken in RAG-Systemen) gelöst werden (Rathod & Anurag, 2024). Retrieval-Augmented-Generation (RAG)-Systeme bieten eine effektive Methode, um externe Wissensdatenbanken in die Antwortgenerierung von LLMs einzubinden und damit deren Wissenshorizont zu erweitern (Rathod & Anurag, 2024).

5 Vom Chatbot-Konzept zur praktischen Umsetzung: State of the Art 2025

Der Entwicklungsprozess für Chatbots hat sich, insbesondere durch die Fortschritte bei Large Language Models, maßgeblich weiterentwickelt. Während die grundlegende Struktur eines mehrphasigen Vorgehens bestehen bleibt, sind die Inhalte und Methoden jeder Phase im Jahr 2025 stark von KI-Technologien geprägt (vgl. Skuridin & Wynn, 2024; VASS, 2024). Typischerweise umfasst dieser Prozess, angepasst an die modernen Gegebenheiten, folgende Kernphasen:

1. *Analyse und Strategie:* Am Anfang steht weiterhin die Analyse der Zielgruppe, der Nutzerbedürfnisse („Jobs-to-be-Done“, Christensen et al., 2016) und der bestehenden Customer Journey. KI-gestützte Tools ermöglichen heute eine tiefere Exploration großer Datenmengen (z. B. aus Support-Anfragen, Online-Verhalten), um präzisere Einblicke in Kundenpräferenzen und Pain Points zu gewinnen (Exovia, 2024; Technobase, 2024). Darauf aufbauend wird ein strategisches *Konzept* entwickelt. Dieses definiert nicht nur den spezifischen Use Case und die Ziele des Chatbots, sondern berücksichtigt auch LLM-spezifische Aspekte wie die Gestaltung der Bot-Persönlichkeit mittels System Prompts und die Definition der Wissensbasis, falls Retrieval-Augmented Generation (RAG) genutzt wird (Built In, 2024; VASS, 2024). Entscheidend ist zudem die frühe Definition relevanter Key Performance Indicators (KPIs), die über traditionelle Metriken hinausgehen und Aspekte wie die Qualität der KI-Interaktion (z. B. Halluzinati-

- onsrate, Nutzerzufriedenheit mit KI-Antworten) und die tatsächliche Automatisierungsleistung (z. B. Containment Rate, Resolution Rate) abbilden (Calabrio, 2024; vgl. auch wissenschaftliche Diskussionen zu Metriken bei Przegalska et al., 2019).
2. *Design (Conversation-&KI-Architektur)*: Diese Phase wandelt sich vom reinen Dialogdesign hin zu einem integrierten Design von Konversation und KI-System. Zentral sind hier das *Prompt Engineering* – die Kunst, dem LLM präzise Anweisungen zu geben (Li et al., 2024; Schulhoff et al., 2024) – und, falls externe Wissensquellen genutzt werden, das Design der *RAG-Architektur* (Lewis et al., 2020). Es muss festgelegt werden, wie der Bot kontextuell verstehen, auf externe Daten zugreifen und menschenähnlich antworten soll, wobei auch die über System Prompts definierte Persönlichkeit konsequent umgesetzt wird (Service Innovation, 2024; Tamoyan et al., 2024).
 3. *Entwicklung und Integration*: Erst wenn das Konzept und das Design stehen, beginnt die technische *Entwicklung*. Dies umfasst die Auswahl oder das Fine-Tuning des passenden LLMs (Open Source vs. API), die Implementierung der RAG-Pipeline (inkl. Vektor-Datenbanken), die Entwicklung notwendiger *Integrationen* zu Backend-Systemen (z. B. CRM, ERP) mittels APIs und die Bereitstellung spezifischer Funktionalitäten (oft durch die Anbindung des LLMs an externe Tools) (Pereira & Díaz, 2018; VASS, 2024). Frameworks wie LangChain oder Rasa erleichtern diese technischen Aufgaben (Annas & Wibisono, 2024; Kiran et al., 2024).
 4. *Testing und Evaluierung*: Die Testphase gewinnt bei LLM-basierten Systemen enorm an Bedeutung. Neben klassischen Tests (Unit-, Integration-, End-to-End-Tests) sind spezifische Evaluierungen zur *Zuverlässigkeit und Sicherheit* der KI zentral. Dazu gehören Tests auf Faktenkorrektheit (Minimierung von Halluzinationen), die Überprüfung auf unerwünschte Verzerrungen (Bias Audits) und Sicherheitstests (z. B. gegen Prompt Injection) (Bolzhauer AG, 2024; Gallegos et al., 2023; Botpress, 2025a, b). Die Evaluierung sollte sowohl automatisiert als auch durch menschliche Prüfer erfolgen (vgl. Dell’Acqua et al., 2023; Nowakowski et al., 2023).
 5. *Deployment und Betrieb*: Nach erfolgreichem Testen erfolgt die *Produktivsetzung*, oft schrittweise (z. B. als Beta-Version für eine begrenzte Nutzergruppe). Im laufenden Betrieb sind *kontinuierliches Monitoring* der Performance, das Sammeln von Nutzerfeedback und die *kontinuierliche Optimierung* unerlässlich (Futureofvoice.com, 2021; VASS, 2024). Bei LLM-Systemen beinhaltet dies insbesondere die Aktualisierung der RAG-Wissensbasis und die Anpassung von Prompts basierend auf realen Interaktionsdaten.
 6. *Change Management und Governance*: Die Einführung von KI-Systemen erfordert die *Vorbereitung der Mitarbeiter* auf neue Arbeitsweisen und den Umgang mit der Technologie (Koseva Stefanova, 2023). Gleichzeitig müssen klare *Governance-Strukturen* und Prozesse etabliert werden, um ethische Richtlinien und regulatorische Vorgaben (z. B. EU AI Act) einzuhalten (Mökander et al., 2023).

Obwohl die technische Entwicklung durch Frameworks und Plattformen zugänglicher wird (Euronews, 2025), bleibt ein fundiertes strategisches und konzeptionelles Fundament, das die spezifischen Eigenschaften von LLMs berücksichtigt, entscheidend für den Erfolg (Hundertmark, 2020).

5.1 Das LLM-basierte Conversational-AI-Konzept als Grundlage für den Erfolg

Um ein Chatbot-Projekt im Zeitalter der Large Language Models zum Erfolg zu führen und dabei Risiken wie Halluzinationen oder unerwünschte Verzerrungen (Bias) zu minimieren, ist es nach wie vor unerlässlich, ein gutes, spezifisch auf LLMs zugeschnittenes Konzept zu erarbeiten (Built In, 2024; Userlike, 2024). Die Erwartungen an LLM-basierte Conversational AI sollten dabei realistisch sein: Trotz ihrer beeindruckenden Fähigkeiten sind sie keine universellen Problemlöser. Es bleibt sinnvoll, mit einem klar definierten Anwendungsfall oder einem Prototypen zu starten (Minimum Viable Product, MVP) und diesen schrittweise, basierend auf Nutzerfeedback und gemessener Performance, zu erweitern und zu optimieren (Built In, 2024; Janssen et al., 2022). Das Konzept umfasst dabei nicht mehr nur das klassische Dialogdesign, sondern maßgeblich auch das *Prompt Engineering* (die Gestaltung der Anweisungen für das LLM), das Design der *Retrieval-Augmented-Generation (RAG)*-Architektur (falls externe Wissensquellen genutzt werden), die Definition der *Bot-Persönlichkeit* über System Prompts und die Verankerung *ethischer Leitplanken* (Li et al., 2024; Lewis et al., 2020; Mökander et al., 2023).

5.2 Fragen, die vor der Entwicklung von virtuellen Assistenten gestellt werden sollten

Bevor mit der technischen Entwicklung eines LLM-basierten virtuellen Assistenten begonnen wird, ist es entscheidend, eine Reihe strategischer, technischer und operativer Fragen zu klären. Diese helfen, den Umfang zu definieren, Risiken zu minimieren und sicherzustellen, dass das Projekt die gewünschten Ziele erreicht. Die folgende Gliederung basiert auf etablierten Projektmanagement-Ansätzen, ergänzt um spezifische Überlegungen für LLMs, wie sie auch in der aktuellen Forschung diskutiert werden.

5.2.1 Businessfragen

- Bedarf und Mehrwert: Gibt es wirklich einen klaren Bedarf für einen *LLM*-Chatbot? Kann der erwartete Mehrwert (z. B. durch Bearbeitung komplexerer Anfragen, verbesserte CX) die höheren Entwicklungs- und Betriebskosten rechtfertigen? (Implikation: Nicht jeder Chatbot braucht ein LLM; vgl. Mhatre et al., 2024).
- Konkretes Problem & Use Case: Welches spezifische Problem soll der Bot lösen? Welcher klar definierte Anwendungsfall soll initial implementiert werden (MVP-

Ansatz)? (Implikation: Fokussierung statt „Alles auf einmal“; vgl. Mhatre et al., 2024).

- Erfolgsmessung (KPIs): Wurden spezifische, messbare KPIs definiert (z. B. Halluzinationsrate, Task Completion Rate, CSAT, Cost per Automated Conversation)? Verfügt die gewählte Plattform/das Framework über die notwendigen Analysefähigkeiten? (Implikation: Erfolg muss messbar sein; vgl. Mhatre et al., 2024).
- Themenumfang: Welchen inhaltlichen Umfang soll der Chatbot abdecken? Ist eine klare Abgrenzung möglich, insbesondere wenn RAG mit einer lokalen Wissensbasis (LKB) genutzt wird? (Implikation: Umfang beeinflusst Komplexität und Datenbedarf; vgl. Zhang et al., 2024; Annas & Wibisono, 2024).
- Risikobewertung vor Einsatz: Wurden Methoden zur Vorhersage der Nutzerakzeptanz oder potenziellen Popularität evaluiert, um das hohe Investitionsrisiko zu minimieren, bevor der Chatbot breit ausgerollt wird? (vgl. Gao et al., 2021 zur Popularitätsvorhersage).

5.2.2 Marketingfragen

- Customer Journey Integration: An welchem Punkt der Kundenreise soll der Bot primär eingesetzt werden (z. B. Erstkontakt, Support, Upselling)? Welches konkrete Marketing- oder Vertriebsziel soll er unterstützen? (Implikation: Der Bot muss strategisch platziert werden; vgl. Burgan et al., 2024).
- Nutzer-Awareness: Wie werden die Nutzer nach dem Go-Live auf den neuen Bot aufmerksam gemacht und zur Nutzung ermutigt? (Implikation: Ein guter Bot nützt nichts, wenn ihn keiner kennt/nutzt; vgl. Gong et al., 2024).

5.2.3 Technische Fragen

- Last & Skalierung: Mit wie vielen Nutzern und Interaktionen pro Tag/Spitzenlast wird gerechnet? Ist die geplante Architektur (API vs. Self-Hosting) dafür ausgelegt? (Implikation: LLMs können ressourcenintensiv sein; vgl. Zikai Zhou et al., 2025).
- Entwicklungsansatz: Soll auf eine fertige SaaS-Lösung, eine Low-Code-Plattform oder eine Eigenentwicklung (ggf. mit Frameworks wie LangChain/Rasa) gesetzt werden? Welche Vor- und Nachteile ergeben sich bezüglich Kosten, Flexibilität und Datenkontrolle? (Implikation: Technologiewahl hat weitreichende Folgen; vgl. Grandi et al., 2024; Annas & Wibisono, 2024).
- Daten (Analyse & RAG/Fine-Tuning): Welche Daten sollen zur initialen Analyse der Kundenerwartungen genutzt werden? Welche Daten dienen als lokale Wissensbasis (LKB) für RAG oder potenzielles Fine-Tuning? Wie werden die Qualität, Aktualität und Sicherheit dieser (oft lokalen) Datenbasis gewährleistet? (Implikation: Datenqualität und -aktualität sind entscheidend für RAG; vgl. Zhang et al., 2024; Burgan et al., 2024; Joshi et al., 2024).
- LLM-Auswahl: Welches LLM (proprietäre API wie OpenAI/Anthropic/Google vs. Open Source wie Llama/Mistral, ggf. lokal gehostet) soll eingesetzt werden? Welche Kriterien (Leistung, Kosten, Datenschutz/Sicherheit bei lokaler vs. API-Nutzung, Anpassbarkeit, Latenz) sind entscheidend? (Implikation: Keine „One-

size-fits-all-Lösung“, Sicherheitsaspekte beachten; vgl. Burgan et al., 2024; Tai & Tannier, 2025; Nze, 2024; Zhang et al., 2024).

- RAG-Design: Welches RAG-Design (einfacher Vektorabruf, GraphRAG, Multi-Agent RAG etc.) ist für den Anwendungsfall am besten geeignet, um relevante Informationen aus der LKB zu finden und Halluzinationen zu minimieren? (Implikation: RAG-Qualität beeinflusst Antwortgüte stark; vgl. Chang et al., 2024; Lin et al., 2025).
- Halluzinations-Management: Wie soll mit potenziell falschen oder unbelegten Antworten (Halluzinationen) des LLMs umgegangen werden? Welche Strategien (RAG mit priorisierter LKB, Prompting, Output-Validierung) werden implementiert? (Implikation: Wichtig für Vertrauen und Zuverlässigkeit; vgl. Luo et al., 2025; Sharma et al., 2024; Zhang et al., 2024).
- Kanäle & Schnittstellen: Für welche Messaging-Plattform(en) oder Kanäle (Web, App, Telefonie) wird der Chatbot entwickelt? Welche technischen Schnittstellen (APIs) zu internen oder externen Systemen werden benötigt? (Implikation: Omnichannel-Fähigkeit und Systemintegration planen; vgl. Demarco et al., 2024).
- Sprachunterstützung: Welche Sprachen muss der Bot beherrschen? Ist das gewählte LLM dafür geeignet oder ist zusätzliches Fine-Tuning für spezifische (ggf. „Low-Resource“) Sprachen notwendig? (Implikation: Mehrsprachigkeit kann komplex sein; vgl. Joshi et al., 2024).
- Fine-Tuning-Methoden: Falls Fine-Tuning nötig ist: Welche Methode ist geeignet (z. B. Full Fine-Tuning, Parameter-Efficient Fine-Tuning wie LoRA/QLoRA, Instruction Tuning)? Wie wirkt sich dies auf Performance und Ressourcen aus (ggf. bei lokaler Implementierung)? (Implikation: Wahl beeinflusst Ressourcenbedarf und Ergebnis; vgl. Joshi et al., 2024; Zikai Zhou et al., 2025).
- Compliance & Ethik: Wie kann die Einhaltung relevanter Vorschriften (z. B. EU AI Act, DSGVO, insbesondere bei Nutzung persönlicher Daten zur Intent-Erkennung oder im Kontext, und ethischer Richtlinien (Fairness, Transparenz, Vermeidung von Bias) technisch und prozessual sichergestellt werden? (Implikation: Gesetzliche und ethische Anforderungen frühzeitig berücksichtigen; vgl. Ho-Dac, 2024; Rességuier & Ufert, 2023; Nze, 2024; Park, 2022).

5.2.4 Operative Fragen

- Budget: Welches Budget steht für Entwicklung, Implementierung *und* den laufenden Betrieb (API-Kosten/Hosting, Monitoring, LKB-Updates, Optimierung) zur Verfügung? (Implikation: LLM-Betriebskosten können variabel und signifikant sein; vgl. Zikai Zhou et al., 2025).
- Personal & Kompetenzen: Steht ausreichend Personal mit den notwendigen Kompetenzen (Prompt Engineering, Data Science, MLOps, KI-Ethik, RAG-Management) für genügend Zeit zur Verfügung? Ist externe Unterstützung geplant? (Implikation: LLM-Projekte erfordern neue Skill Sets; vgl. Desmond & Brachman, 2024; Lakshmi Swathi Sreedhar, 2024).
- Zeitrahmen: Wie viel Zeit steht realistischerweise für Konzept, Entwicklung, Testing und Implementierung zur Verfügung? (Implikation: LLM-Projekte sind oft komplexer als klassische Softwareprojekte).

Die sorgfältige Beantwortung dieser Fragen im Vorfeld legt den Grundstein für eine erfolgreiche und verantwortungsvolle Implementierung eines LLM-basierten Chatbots.

6 Wie Conversational AI funktioniert: LLMs, Herausforderungen und Integrationen

Um effektiv mit Chatbots – oder präziser: mit moderner Conversational AI – zu arbeiten, ist ein grundlegendes Verständnis ihrer Funktionsweise, der aktuellen technologischen Basis sowie der damit verbundenen Herausforderungen und Integrationsnotwendigkeiten unerlässlich. Die Technologie hat sich seit 2020 rasant weiterentwickelt. Während frühere Systeme oft auf expliziten Regeln oder statistischen Methoden zur Erkennung von Intents und Entitäten basierten, dominieren heute Large Language Models die Landschaft und ermöglichen wesentlich komplexere und menschenähnlichere Interaktionen.

6.1 Die technologische Basis: Large Language Models und verwandte Konzepte

Moderne virtuelle Assistenten unterscheiden sich fundamental von ihren Vorgängern. Die Basis bilden nicht mehr primär manuell definierte Regeln oder einfache Keyword-Erkennung, sondern hoch entwickelte KI-Modelle, die auf riesigen Datenmengen trainiert wurden.

- *Historischer Kontext: Intents, Utterances, Entities:* Traditionelle Chatbots analysierten Sprache mithilfe von drei Kernkomponenten: *Intents* (Absichten des Nutzers), *Utterances* (konkrete Äußerungen/Trainingsphrasen) und *Entities* (spezifische Informationen wie Namen, Orte, Daten) (Engati, 2025; Verloop.io, 2025; Microsoft Learn, 2025). Eine Natural Language Processing (NLP) Engine zerlegte die Nutzereingabe und ordnete sie vordefinierten Kategorien zu (Lee et al., 2022; Lyngdoh & Raghavendra, 2022). Dieser Ansatz erforderte umfangreiches Training mit vielen Beispielsätzen (Utterances) pro Intent (Microsoft Learn, 2025; Lyngdoh & Raghavendra, 2022) und war oft limitiert im Umgang mit Variationen oder unerwarteten Anfragen (Haresamudram et al., 2025; SpringApps, 2025). Diese Terminologie ist in einigen (oft hybriden) Systemen oder Entwicklungsplattformen zwar noch präsent (Park, 2022), repräsentiert aber nicht mehr die Kernfunktionsweise führender Conversational AI.
- *Large Language Models (LLMs):* Die heutige Generation basiert maßgeblich auf LLMs, die auf der Transformer-Architektur aufbauen (Vaswani et al., 2017; Khan & Orii, 2024). Diese Modelle werden auf gigantischen Text- und Codedatensätzen vortrainiert und lernen dabei komplexe statistische Muster, Grammatik, Faktenwissen und sogar Schlussfolgerungsfähigkeiten (Bommasani et al., 2022; Wei et al., 2024). Sie „verstehen“ und generieren Sprache, indem sie probabilis-

tisch das wahrscheinlichste nächste Wort (oder Token) vorhersagen (Wei et al., 2024). Ihre Stärke liegt im Erkennen von Kontext über lange Textpassagen hinweg (Context Window) und in ihrer Fähigkeit, sich durch Fine-Tuning oder Prompt Engineering an spezifische Aufgaben anzupassen (Brown et al., 2020). Führende Modelle im Jahr 2025 sind z. B. die GPT-Serie von OpenAI, Gemini von Google oder Claude von Anthropic (s. auch Abschn. 7.1 des überarbeiteten Artikels).

- *Retrieval-Augmented Generation (RAG)*: Da LLMs Wissen nur bis zum Stand ihrer Trainingsdaten besitzen und zu „Halluzinationen“ (faktisch falschen Aussagen) neigen können, ist RAG eine Schlüsseltechnologie für den Unternehmens-einsatz (Kabbay, 2024). RAG kombiniert das LLM mit einer externen, aktuellen Wissensdatenbank (z. B. Unternehmensdokumente, Produktdatenbanken), oft über Vektor-Datenbanken. Das System sucht (Retrieval) zuerst relevante Informationen und stellt diese dem LLM als Kontext für die Antwortgenerierung bereit (Augmented Generation) (Lewis et al., 2020; Chen & Kumar, 2024). Dies erhöht die Faktentreue und ermöglicht die Nutzung unternehmensspezifischer Daten (arxiv.org, 2024a).
- *Multimodalität*: Neuere LLMs können über Text hinaus auch andere Datenformate wie Bilder oder Audio verarbeiten (Multimodalität), was natürlichere Interaktionen ermöglicht (Ghosh & Deepa, 2024; Kalakuntla et al., 2023).
- *Implizite Intent- und Entity-Erkennung*: LLMs erkennen die Absicht und relevante Informationen oft implizit aus dem Kontext der Nutzereingabe, ohne dass explizite Intents oder Entities vordefiniert werden müssen (Chen & Wang, 2025; Shang et al., 2024). Sie können mit Mehrdeutigkeiten besser umgehen als frühere Systeme (Mehrparvar & Pezzelle, 2024).

6.2 Herausforderungen in der Entwicklung moderner virtueller Assistenten

Die Implementierung moderner, LLM-basierter virtueller Assistenten ist mit neuen und komplexeren Herausforderungen verbunden als die Entwicklung traditioneller Systeme.

- *Halluzinationen und Faktentreue*: LLMs können überzeugend klingende, aber faktisch falsche oder unbelegte Informationen generieren („Halluzinationen“) (Fieldfisher, 2023; McKinsey Global Institute, 2025, S. 8). Dies ist eine der größten Herausforderungen, da es das Vertrauen der Nutzer untergräbt und zu Fehlinformationen führen kann. RAG hilft, dieses Problem zu mitigieren, indem Antworten auf externe Fakten gestützt werden, eliminiert es aber nicht vollständig (Luo et al., 2025).
- *Bias und Fairness*: LLMs lernen aus riesigen Datenmengen, die oft gesellschaftliche Vorurteile (Bias) widerspiegeln. Diese können von den Modellen übernommen und sogar verstärkt werden (Gallegos et al., 2023). Dies kann zu diskriminierenden oder unfairen Ergebnissen führen, was ethisch und rechtlich problematisch ist (Mökander et al., 2023).

- *Datenschutz und Sicherheit:* Der Einsatz von LLMs wirft erhebliche Datenschutzfragen auf (EY, 2025, S. 5). Werden sensible Daten aus Prompts oder RAG-Quellen unsicher verarbeitet oder gespeichert? Besteht die Gefahr, dass das Modell sensible Informationen aus seinen Trainingsdaten preisgibt (Privacy International, 2024)? Die Einhaltung der DSGVO und neuer Regulierungen (The Barrister Group, 2025), wie des EU AI Act (European Union, 2024) ist zwingend erforderlich. Zudem entstehen neue Sicherheitsrisiken wie Prompt Injection (Manipulation des Modells durch geschickte Eingaben) oder Jailbreaking (Umgehung von Sicherheitsbeschränkungen) (Goodman, 2023).
- *Kontrolle, Steuerbarkeit und Erklärbarkeit:* Es ist oft schwierig, den Output von LLMs präzise zu steuern oder vorherzusagen. Ihre interne Funktionsweise ist komplex und oft nicht vollständig nachvollziehbar („Black-Box-Problem“) (Fieldfisher, 2023). Dies erschwert die Fehlersuche, die Validierung von Antworten und die Erfüllung von Rechenschaftspflichten (Mökander et al., 2023).
- *Kosten, Latenz und Skalierbarkeit:* Das Training und der Betrieb großer LLMs sind extrem rechen- und energieintensiv (Deloitte, 2024, S. 27 ff.). Die Nutzung über APIs ist oft mit variablen Kosten pro Token (verarbeiteter Texteinheit) verbunden, die bei hoher Auslastung erheblich sein können (McKinsey Global Institute, 2025, S. 36). Auch die Antwortzeiten (Latenz) können eine Herausforderung darstellen. Die Skalierung für Millionen von Nutzern erfordert eine robuste Infrastruktur (Zikai Zhou et al., 2025).
- *Datenqualität und -management:* Die Qualität der Antworten, insbesondere bei RAG-Systemen, hängt stark von der Qualität, Aktualität und Relevanz der zugrunde liegenden Wissensbasis ab (Kabbay, 2024; Zhang et al., 2024). Das Management dieser Datenquellen wird zu einer Kernaufgabe (Berndt, 2020). Die Integration mit bestehenden, oft heterogenen Unternehmenssystemen ist technisch anspruchsvoll (MobiDev, 2025; Techstack, 2025; EY, 2025, S. 11).
- *Sprachliche Nuancen und Low-Resource-Sprachen:* Obwohl LLMs generell gut mit Sprache umgehen, bleiben feine Nuancen, Dialekte, Slang oder sehr spezifischer Fachjargon Herausforderungen, die oft gezieltes Fine-Tuning erfordern (Joshi et al., 2024). Die Leistung in Sprachen mit wenigen digitalen Ressourcen (Low-Resource Languages) ist oft deutlich schlechter (DataCamp, 2025).
- *Technologieauswahl und Lock-in:* Unternehmen stehen vor der Wahl zwischen der Nutzung mächtiger, aber proprietärer Modelle über APIs (z. B. OpenAI, Anthropic), dem Einsatz von Open-Source-Modellen (z. B. Mistral), die mehr Kontrolle, aber auch mehr Aufwand bedeuten, oder der Nutzung von Plattformen der großen Cloud-Anbieter (AWS, Google Cloud, Azure) (Luchaninov, 2025; Ismail et al., 2024; Burgan et al., 2024). Jede Option birgt eigene Risiken bezüglich Abhängigkeiten (Lock-in), Kosten und Datenschutz (Berndt, 2020).
- *Planung, Wartung und MLOps:* LLM-Projekte erfordern eine andere Art der Planung und Wartung als traditionelle Software (Kabbay, 2024; VASS, 2024). Kontinuierliches Monitoring der Modell-Performance, Evaluierung gegen Halluzinationen und Bias, Anpassung von Prompts und die Aktualisierung von RAG-Datenbanken sind Daueraufgaben, die spezialisierte MLOps-Prozesse (Machine Learning Operations) erfordern (Kabbay, 2024; VASS, 2024; Nowakowski et al.,

Moderne virtuelle Assistenten



Abb. 2 Gegenüberstellung der Vor- und Nachteile moderner virtueller Assistenten

2023). Die schnelle Entwicklungsgeschwindigkeit der Modelle erfordert zudem eine agile, langfristige Roadmap (McKinsey Superagency, Jan 2025, S. 36).

Abb. 2 zeigt eine Gegenüberstellung der Vor- und Nachteile moderner virtueller Assistenten.

6.3 Integrationen: Virtuelle Assistenten im Unternehmensökosystem

Moderne virtuelle Assistenten sind selten isolierte Insellösungen. Ihr wahrer Nutzen entfaltet sich erst durch die nahtlose Integration in das bestehende technologische und prozessuale Ökosystem eines Unternehmens (Giuri, 2023; Pereira & Díaz, 2018). Die technischen Herausforderungen liegen oft weniger im virtuellen Assistenten selbst als in dieser Integration.

- *Anbindung an Backend-Systeme via APIs:* Application Programming Interfaces (APIs) sind die Standardschnittstellen, über die virtuelle Assistenten mit externen Systemen kommunizieren (Giuri, 2023; Fischer et al., 2021).
 - *RESTful APIs:* Weit verbreitet für Web-Services, nutzen Standard-HTTP-Methoden (GET, POST etc.) und sind zustandslos, was die Integration mit vielen Web-Diensten erleichtert (AWS, 2025).

- *GraphQL APIs*: Bieten eine flexiblere Alternative, bei der der Client (Chatbot) genau spezifizieren kann, welche Daten er benötigt. Dies reduziert unnötigen Datenverkehr (Over-/Under-Fetching) und kann die Effizienz steigern, ist aber komplexer in der Einrichtung (AWS, 2025). Die Wahl zwischen REST und GraphQL hängt vom spezifischen Anwendungsfall ab (s. AWS, 2025).
- *Datenbankintegration*: Direkte oder indirekte Anbindung an Unternehmensdatenbanken (SQL, NoSQL) ist entscheidend, um dynamische, aktuelle Informationen bereitzustellen (z. B. Bestellstatus, Produktverfügbarkeit) oder als Wissensquelle für RAG-Systeme zu dienen. Sicherheitsaspekte (Zugriffskontrolle, Schutz sensibler Daten) sind hierbei kritisch (Hong et al., 2025).
- *Integration mit Kernsystemen (CRM, ERP etc.)*: Um komplexe Geschäftsprozesse zu automatisieren oder als KI-Agent zu agieren (Deloitte, 2024, S. 17), müssen Chatbots oft tief in Kernsysteme wie Customer Relationship Management (CRM) oder Enterprise Resource Planning (ERP) integriert werden (Luchaninov, 2025). Dies ermöglicht z. B. das Auslösen von Bestellungen, das Aktualisieren von Kundendaten oder das Management von Berechtigungen (Wicki, 2019).
- *Webhooks*: Ermöglichen eine Echtzeitkommunikation, bei der externe Systeme den Chatbot aktiv über Ereignisse informieren (z. B. Bestellbestätigung, Status-Update), anstatt dass der Chatbot ständig nachfragen muss (Polling) (FastBots.ai, 2025a; Communicate.io, 2025; Báez et al., 2020).
- *Ecosystem Orchestration*: Erfolgreiche Integration erfordert oft die Orchestrierung verschiedener Partner und Technologien im Ökosystem des Unternehmens (Jasmin et al., 2022; EY, 2025, S. 28).

Die Komplexität dieser Integrationen, insbesondere mit Altsystemen (Legacy Systems), stellt oft eine erhebliche Hürde dar und erfordert sorgfältige Planung und technisches Know-how (Luchaninov, 2025).

7 Tool-Evaluierung

Der Chatbot-Markt hat sich seit den frühen Prognosen rasant weiterentwickelt. War damals von einem jährlichen Wachstum von ca. 24,3 % die Rede, bestätigen aktuelle Prognosen diese Dynamik, wenn auch auf einem wesentlich höheren Niveau. Der globale Conversational-AI-Markt wurde für 2024 auf 7,76 Mrd. USD geschätzt und soll bis 2030 auf 27,29 Mrd. USD anwachsen, was einer durchschnittlichen jährlichen Wachstumsrate (CAGR) von rund 23,3 % entspricht (Grand View Research, 2024). Andere Analysen prognostizieren ähnliche Wachstumsraten, teilweise sogar bis zu 30 % (MarketsandMarkets, 2024). Dieses anhaltende Wachstum spiegelt die tiefgreifende Integration von Conversational AI, insbesondere von Large Language Models, in nahezu alle Branchen wider. Für die DACH-Region wird ebenfalls ein starkes Wachstum prognostiziert, wobei der Markt bis 2025 voraussichtlich

1,14 Mrd. EUR erreichen wird, getrieben durch eine hohe Adaptionsrate im Mittelstand und die steigende Nachfrage nach deutschsprachigen KI-Lösungen (Qualimero, 2025).

Die Auswahl des richtigen Tools oder Anbieters ist angesichts dieser Dynamik und der technologischen Vielfalt eine noch größere Herausforderung geworden. Die zentrale Frage lautet nicht mehr nur, ob ein regelbasierter Bot ausreicht oder NLP-Komponenten benötigt werden, sondern welche Art von KI-Architektur – von spezialisierten Modellen bis hin zu großen Foundation Models – für den spezifischen Anwendungsfall am besten geeignet ist. Die Unterscheidungskraft liegt heute im Verständnis der zugrunde liegenden KI-Modelle, ihrer Trainingsdaten, ihrer Fähigkeiten und ihrer Grenzen (Harahap et al., 2025).

7.1 Die moderne Landschaft der Conversational-AI-Technologien

Die Tool-Landschaft im Jahr 2025 ist komplex und vielschichtig. Sie lässt sich grob in folgende Kategorien unterteilen:

1. *Große Sprachmodelle (LLMs) als APIs*: Führende KI-Forschungsunternehmen bieten ihre leistungsstärksten Modelle über Programmierschnittstellen (APIs) an. Dazu gehören:
 - *OpenAI*: Mit Modellen wie GPT-4o und früheren Versionen, die den Markt maßgeblich geprägt haben. ChatGPT, basierend auf diesen Modellen, dominiert weiterhin den Endnutzermarkt (Bailyn, 2025).
 - *Google*: Mit der Gemini-Modellfamilie (Ultra, Pro, Flash), die multimodal (Text, Bild, Audio, Code) agieren kann und tief in das Google-Ökosystem (vgl. Wikipedia, 2025) integriert ist (Lee et al., 2025).
 - *Anthropic*: Mit der Claude-Modellfamilie (z. B. Claude 3.5), bekannt für ihren Fokus auf Sicherheit, ethische KI und nuancierte Konversationsfähigkeiten (Bailyn, 2025).
 - *Andere Anbieter*: Meta (mit Llama-Modellen; Qin et al., 2023). Mistral AI, Cohere und weitere spezialisierte Anbieter ergänzen das Feld.
 - Diese APIs bieten hohe Leistungsfähigkeit, erfordern aber eine Abhängigkeit vom Anbieter und werfen Fragen bezüglich Kosten (oft Token-basiert) und Datenschutz auf (McKinsey Global Institute, 2025, S. 36).
2. *Cloud-Plattformen für KI*: Die großen Hyperscaler integrieren LLMs und Entwicklerwerkzeuge in ihre Cloud-Angebote:
 - *Google Cloud Vertex AI*: Bietet Zugriff auf Gemini-Modelle und Werkzeuge für Training, Deployment und Management von KI-Anwendungen (Google Cloud Docs, o. J.).
 - *Microsoft Azure AI*: Integriert OpenAI-Modelle und bietet eine breite Palette an KI-Diensten und Entwicklerwerkzeugen (Microsoft Learn).
 - *Amazon Web Services (AWS)*: Mit Amazon Bedrock als Plattform für den Zugriff auf verschiedene Foundation Models und Amazon Lex für die Erstel-

lung von Konversationsschnittstellen (AWS Documentation; Hnatushenko et al., 2024).

- Diese Plattformen vereinfachen die Integration von KI in bestehende Cloud-Infrastrukturen.
3. *Open-Source-Modelle und Frameworks*: Eine wachsende Zahl von Modellen und Frameworks wird quelloffen zur Verfügung gestellt:
 - *Modelle*: Metas Llama-Serie (Touvron et al., 2023), Mistral-Modelle, Googles Gemma etc. bieten Alternativen zu proprietären APIs und ermöglichen lokales Hosting für mehr Datenkontrolle (Kumar, 2024).
 - *Frameworks*:
 - *Rasa*: Ein beliebtes Python-Framework für fortgeschrittene, kontextbezogene Chatbots mit starkem Fokus auf NLU und Dialogmanagement (Pradana et al., 2022; Kale et al., 2025).
 - *Botpress*: Ein weiteres Open Source Framework (TypeScript), das einen visuellen Editor bietet und auch für weniger technische Nutzer zugänglich ist (Botpress, 2025c).
 - *LangChain & LlamaIndex*: Frameworks zur Orchestrierung von LLM-Anwendungen, insbesondere für die Implementierung von Retrieval-Augmented Generation (RAG) und komplexen Agenten-Workflows (Zhang et al., 2024).
 - Open Source bietet Flexibilität und Kontrolle, erfordert aber oft mehr technisches Know-how und Ressourcen für Implementierung und Wartung (Designveloper, 2025).
 4. *Spezialisierte Chatbot-Plattformen (kommerziell)*: Viele Anbieter bieten End-to-End-Plattformen für die Erstellung, Verwaltung und Analyse von Chatbots, oft mit No-Code- oder Low-Code-Ansätzen und spezifischen Branchenlösungen. (Dagkoulis & Moussiades, 2023).
 5. *Vektordatenbanken*: Für RAG-Systeme unerlässlich, speichern diese Datenbanken Daten in Form von Vektoreinbettungen, um schnelle Ähnlichkeitssuchen zu ermöglichen (z. B. Pinecone, Weaviate, Milvus) (AWS (Amazon Web Services)).

7.2 Evaluierungskriterien im LLM-Zeitalter

Die Bewertung von Conversational AI Tools muss die spezifischen Eigenschaften und Herausforderungen von LLMs berücksichtigen. Einfache, regelbasierte Vergleiche reichen nicht mehr aus. Folgende Kriterien sind entscheidend:

1. *Leistung und Genauigkeit*:
 - *Antwortqualität*: Flüssigkeit, Kohärenz, Relevanz und Korrektheit der generierten Antworten (DataCamp, 2025).
 - *Halluzinationsrate*: Wie oft generiert das Modell faktisch falsche oder unbelegte Informationen? Methoden zur Erkennung und Reduzierung sind essenziell (Li et al., 2023).

- *Kontextverständnis*: Fähigkeit, den Gesprächskontext über mehrere Interaktionen hinweg zu verstehen und zu nutzen (Bai et al., 2024).
 - *Aufgabenerfüllung (Task Completion)*: Wie gut löst der Chatbot die ihm zugedachten Aufgaben (z. B. Task Success Rate) (Liu et al., 2023)?
 - *Robustheit*: Wie gut geht das Modell mit unerwarteten Eingaben, Mehrdeutigkeiten oder verschiedenen Formulierungen um (Zhang et al., 2024)?
2. *Retrieval-Augmented Generation (RAG) – falls relevant*:
 - *Relevanz der Abrufe*: Qualität und Passgenauigkeit der aus der Wissensbasis abgerufenen Informationen.
 - *Faktentreue*: Wie gut stützt sich die generierte Antwort auf die abgerufenen Fakten?
 - *Umgang mit Wissenslücken*: Wie reagiert das System, wenn keine relevanten Informationen gefunden werden (Yu et al., 2024)?
 3. *Sicherheit und Datenschutz*:
 - *Robustheit gegen Angriffe*: Wie anfällig ist das Modell für Prompt Injection, Jailbreaking etc. (Goodman, 2023)?
 - *Datenschutzkonformität*: Werden Datenschutzbestimmungen (insbesondere GDPR/DSGVO in DACH) eingehalten (van Mil & Quintais, 2022)? Wo werden Daten gespeichert und verarbeitet (Leschanowsky et al., 2023)? Gibt es Mechanismen zur Datenanonymisierung (Userlike, 2024)?
 4. *Bias und Fairness*:
 - Wurden Maßnahmen ergriffen, um schädliche Vorurteile (Bias) im Training und in den Antworten zu erkennen und zu mitigieren (Gallegos et al., 2023)?
 5. *Integrationsfähigkeit und Anpassbarkeit*:
 - Wie einfach lässt sich das Tool in bestehende Systeme (CRM, ERP, Messaging-Kanäle) integrieren (APIs, SDKs) (Designveloper, 2025)?
 - Welche Möglichkeiten gibt es für Fine-Tuning oder Anpassungen an spezifische Unternehmensdaten oder -prozesse (Joshi et al., 2024)?
 6. *Kosten und Effizienz*:
 - *Preisstruktur*: Transparenz der Kosten (API-Aufrufe, Tokens, Lizenzen).
 - *Inferenzgeschwindigkeit (Latenz)*: Wie schnell antwortet der Chatbot?
 - *Ressourcenbedarf*: Rechenleistung und Speicherbedarf (insbesondere bei Self-Hosting) (McKinsey Superagency, Jan 2025, S. 36).
 7. *Benutzerfreundlichkeit und Support*:
 - *Entwicklererfahrung*: Qualität der Dokumentation, Verfügbarkeit von Entwicklerwerkzeugen, Community-Support (bei Open Source).
 - *Endnutzererfahrung*: Intuitivität der Interaktion, Gesprächsfluss (vgl. Gujjar & Kumar, 2025) (Dagkoulis & Moussiades, 2023).

Methoden zur Evaluierung umfassen neben quantitativen Metriken (wie BLEU, ROUGE) (DataCamp, 2025) zunehmend auch menschliche Bewertungen (Likert-Skalen, A/B-Tests) (Deep Tech Consulting GmbH, 2024), und spezialisierte Benchmarks (z. B. für spezifische Fähigkeiten wie logisches Schließen oder Code-Generierung).

Die Evaluierung von Conversational AI Tools im Jahr 2025 ist ein komplexer Prozess, der weit über den Vergleich von Funktionslisten hinausgeht. Unternehmen müssen eine strategische Entscheidung treffen, die technische Leistungsfähigkeit, Integrationsfähigkeit, Kosten, Benutzerfreundlichkeit und vor allem die Einhaltung strenger Datenschutz- und Regulierungsanforderungen (insbesondere in der DACH-Region) berücksichtigt. Die Wahl zwischen mächtigen, aber potenziell kostspieligen und datenschutzrechtlich sensiblen API-Modellen großer Anbieter, flexiblen Cloud-Plattformen und anpassbaren, aber ressourcenintensiveren Open-Source-Lösungen erfordert eine sorgfältige Abwägung der eigenen Ziele, Ressourcen und Risikobereitschaft.

8 Fazit und Ausblick: Die Ära der intelligenten KI-Agenten und Mensch-Maschine-Kollaboration

Die Landschaft der Chatbots hat sich seit der ursprünglichen Veröffentlichung dieses Guides im Jahr 2021 dramatisch verändert. Der Übergang von einfachen, regelbasierten oder frühen NLP-Chatbots zu Systemen, die auf hoch entwickelten Large Language Models basieren, stellt einen fundamentalen Paradigmenwechsel dar (Schmidt & Müller, 2023). Diese Entwicklung hat die Möglichkeiten und Grenzen der Technologie neu definiert und bietet Unternehmen bisher ungeahnte Chancen, ihre Kundeninteraktionen zu revolutionieren und Geschäftsprozesse tiefgreifend zu optimieren.

Obwohl die zugrunde liegende Transformer-Architektur (Vaswani et al., 2017) bereits 2017 vorgestellt wurde, haben Modelle wie die GPT-Serie von OpenAI (z. B. GPT-4, O3) (OpenAI, 2023), Googles Gemini-Familie (Google DeepMind, 2023), Anthropic's Claude-Serie und Open-Source-Alternativen wie Metas Llama (Kumar, 2024; Touvron et al., 2023) oder Modelle von Mistral AI die Fähigkeit von Maschinen, menschliche Sprache zu verstehen und zu generieren, auf ein neues Niveau gehoben. Für den Unternehmenseinsatz entscheidend sind dabei Technologien wie Retrieval-Augmented Generation (RAG), die die generativen Fähigkeiten von LLMs mit gesichertem Unternehmenswissen verknüpfen und so die Faktentreue erhöhen sowie „Halluzinationen“ reduzieren (Lewis et al., 2020; Chen & Kumar, 2024). In der Praxis etablieren sich zudem zunehmend hybride Architekturen, die die Stärken regelbasierter Systeme (für Zuverlässigkeit in Transaktionen) mit der Flexibilität von LLMs (für komplexe Dialoge) kombinieren (Hartmann & Weber, 2024).

8.1 Zentraler Ausblick: Von Chatbots zu KI-Agenten

Die vielleicht bedeutendste Entwicklungslinie ist der Übergang von reaktiven Chatbots zu proaktiven KI-Agenten (Agentic AI) (Wang et al., 2023).

Diese Systeme gehen über das reine Beantworten von Fragen hinaus und sind in der Lage, eigenständig Aufgaben zu planen, zu koordinieren und mithilfe von Tools (Software, APIs etc.) auszuführen (Wang et al., 2023).

Diese Agenten sind kontextbewusst und können basierend auf Nutzerpräferenzen und historischen Daten proaktiv agieren, oft ohne explizite Aufforderung (Deloitte, 2024, S. 14; Meduri, 2024). Frameworks wie Microsofts AutoGen oder LangChain vereinfachen bereits die Entwicklung solcher Multi-Agenten-Systeme (Microsoft, 2023). Die Fähigkeit zur direkten AI-zu-AI-Kommunikation, die effizienter als menschliche Sprache sein kann, wird dabei die Koordination komplexer Workflows weiter beschleunigen (Knight, 2023; Deloitte, 2024, S. 23).

8.2 Technische Trends: Multimodalität und Personalisierung

Die Interaktion mit KI wird zunehmend multimodal. Moderne LLMs wie Googles Gemini (Google DeepMind, 2023) oder OpenAIs GPT-4V/O3 (OpenAI, 2023) können nicht nur Text, sondern auch Bilder, Audio und teilweise Videos verarbeiten und generieren. Dies ermöglicht natürlichere und intuitivere Schnittstellen, die der menschlichen Kommunikation näherkommen und neue Anwendungsfälle erschließen (Deloitte, 2024, S. 5; Xue, 2024). Zukünftige Systeme könnten Emotionen besser erkennen und empathischer reagieren (Zhou et al., 2023), was die Akzeptanz und Effektivität weiter steigern dürfte. Die Personalisierung wird ebenfalls weiter zunehmen, da KI-Systeme aus Interaktionen lernen und sich kontinuierlich an individuelle Nutzerbedürfnisse anpassen (Wei et al., 2024). Gleichzeitig könnten spezialisierte, kleinere Modelle (Small Language Models, SLMs) für spezifische Aufgaben oder den Einsatz auf Edge-Geräten an Bedeutung gewinnen, um die Effizienz zu steigern und Datenschutzbedenken (durch lokale Verarbeitung) zu adressieren (Deloitte, 2024, S. 5, 18).

8.3 Gesellschaftliche und ethische Implikationen

Mit der wachsenden Leistungsfähigkeit und Verbreitung von Conversational AI rücken ethische und gesellschaftliche Fragen stärker in den Fokus. Herausforderungen wie der Datenschutz (insbesondere bei sensiblen Daten und der Gefahr von Datenlecks aus Trainings- oder Nutzerdaten) (Privacy International, 2024), die algorithmische Voreingenommenheit (Bias), die oft aus den Trainingsdaten übernommen wird (Gallegos et al., 2023; Bommasani et al., 2022), die Transparenz von KI-Entscheidungen („Black-Box-Problem“) (Fieldfisher, 2023) und die Sicherheit gegenüber Manipulationen (Prompt Injection, Generierung schädlicher Inhalte) müssen adressiert werden (Goodman, 2023). Regulatorische Rahmenwerke wie der EU AI Act, der seit August 2024 in Kraft ist und dessen Regelungen schrittweise bis 2026/2027 anwendbar werden (mit ersten Verboten ab Februar 2025) (European

Union, 2024), versuchen, Leitplanken für eine verantwortungsvolle Entwicklung und Nutzung zu setzen. Unternehmen müssen proaktiv Governance-Strukturen etablieren und Compliance-by-Design praktizieren sowie verantwortungsvolle AI-Prinzipien implementieren (Mökander et al., 2023). Auch die Auswirkungen auf den Arbeitsmarkt erfordern Aufmerksamkeit, wobei der Fokus auf Umschulung und Förderung von Kompetenzen liegen sollte, die durch KI ergänzt, aber nicht ersetzt werden (Deloitte, 2024, S. 23).

8.4 Strategische Empfehlung

Für Unternehmen ist es entscheidend, Conversational AI nicht nur als Werkzeug zur Effizienzsteigerung zu betrachten, sondern als strategische Komponente, die das Potenzial hat, Geschäftsmodelle und Kundenerlebnisse grundlegend zu transformieren. Die erfolgreiche Implementierung erfordert eine klare Vision, eine durchdachte Strategie, Investitionen in Datenqualität und -management sowie die Bereitschaft zur organisatorischen Anpassung. Entscheidend wird sein, einen pragmatischen, nutzenorientierten Ansatz zu verfolgen, der technologische Möglichkeiten mit strategischen Geschäftszielen und ethischer Verantwortung in Einklang bringt. Nur so kann das volle Potenzial moderner Conversational-AI-Technologien realisiert werden. Der Schlüssel zum Erfolg liegt darin, den Kunden einen echten Mehrwert zu bieten – durch personalisierte, effiziente und gleichzeitig menschliche Interaktionen, unterstützt durch intelligente Technologie.

Erklärung zu konkurrierenden Interessen J. Lehmann hat keine Interessenkonflikte zu erklären, die für den Inhalt dieses Manuskripts relevant sind.

Disclaimer Für die Recherche, Ideenskizzierung und Texterstellung dieses Beitrags wurden KI-gestützte Werkzeuge eingesetzt, insbesondere *OpenAI ChatGPT*, *Perplexity AI* und *Google Gemini*.

OpenAI. (2025, April 29). *ChatGPT* (Version o3) (Large Language Model). OpenAI. <https://chat.openai.com/>

Perplexity AI. (2025, April 29). *Perplexity* (Version pplx-70b) (AI-gestütztes Recherche-Tool). Perplexity AI. <https://www.perplexity.ai/>

Google DeepMind. (2025, April 29). *Gemini Pro* (Version 1.5) (Multimodales Large Language Model). Google. <https://deepmind.google/>

Literatur

- Annas, A., & Wibisono, S. (2024). Implementasi Chatbot Menggunakan Framework Rasa Untuk Layanan Informasi Objek Wisata Di Kabupaten Pemalang. *INTECOMS: Journal of Information Technology and Computer Science*, 7(1), 86–93. <https://doi.org/10.31539/intecom.v7i1.8425>
- AWS. (2025). *GraphQL vs REST API – Difference between API Design ...* – AWS. <https://aws.amazon.com/compare/the-difference-between-graphql-and-rest/>. Zugegriffen am 29.03.2025.
- Báez, M., Daniel, F., Casati, F., & Benatallah, B. (2020). Chatbot integration in few patterns. *IEEE Internet Computing*, 25(3), 52–59. <https://doi.org/10.1109/MIC.2020.3024605>
- Bai, Y., Lv, X., Zhang, J., Lyu, H., Tang, J., Huang, Z., Du, Z., Liu, X., Zeng, A., Hou, L., Dong, Y., Tang, J., & Li, J. (2024, June 19). *LongBench: A bilingual, multitask benchmark for long context understanding*. arXiv. <https://doi.org/10.48550/arXiv.2308.14508>

- Bailyn, E. (2025, März 06). *Top generative AI Chatbots by market share – March 2025*. FirstPageSage. <https://firstpagesage.com/reports/top-generative-ai-chatbots/>. Zugegriffen am 28.03.2025.
- Baktash, J. A., & Dawodi, M. (2023). *Gpt-4: A review on advancements and opportunities in natural language processing*. ArXiv, abs/2305.03195.
- Berndt, M. (2020). *Tech Report: Ein komprimierter Überblick über aktuelle und aufkommende Technologien*. Mittelstand 4.0 Kompetenzzentrum IT-Wirtschaft. <https://www.itwirtschaft.de/materialien/downloads/>. Zugegriffen am 28.03.2025.
- Bolzhauser AG. (2024). *Chatbots im Kundenservice: Transformation. Jetzt*. <https://bolzhauser.de/insights/chatbots-im-kundenservice/>. Zugegriffen am 28.03.2025.
- Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., ... Liang, P. (2022). On the opportunities and risks of foundation models. *Journal of Artificial Intelligence Research*, 75, 1859–1972. <https://doi.org/10.1613/jair.1.13895>
- Botpress. (2025a). *Enterprise Chatbots: Everything you need to know in 2025*. Botpress Blog. <https://botpress.com/blog/enterprise-chatbots>. Zugegriffen am 28.03.2025.
- Botpress. (2025b). *Chatbot-Sicherheitsleitfaden: Risiken und Leitplanken (2025)*. Botpress Blog. <https://botpress.com/de/blog/chatbot-security>. Zugegriffen am 28.03.2025.
- Botpress. (2025c). *14 Best open source Chatbot platforms to use in 2025*. Botpress Blog. <https://botpress.com/blog/open-source-chatbots>. Zugegriffen am 28.03.2025.
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- Built In. (2024). *Best practices for designing effective AI Chatbots*. <https://builtin.com/artificial-intelligence/designing-effective-ai-chatbots>. Zugegriffen am 28.03.2025.
- Burgan, C., Kowalski, J., & Liao, W. (2024). Developing a Retrieval Augmented Generation (RAG) Chatbot App using adaptive Large Language Models (LLM) and LangChain framework. *Proceedings of the West Virginia Academy of Science*, 96(1). <https://doi.org/10.55504/0029-9438.1002>
- Calabrio. (2024). *12 Essential Chatbot performance metrics & KPIs for 2025*. <https://www.calabrio.com/wfo/contact-center-ai/key-chatbot-performance-metrics/>. Zugegriffen am 28.03.2025.
- Chang, C.-Y., Jiang, Z., Rakesh, V., Pan, M., Yeh, C.-C. M., Wang, G., Hu, M., Xu, Z., Zheng, Y., Das, M., & Zou, N. (2024). *MAIN-RAG: Multi-agent filtering retrieval-augmented generation*. arXiv. <https://doi.org/10.48550/arXiv.2407.06956>
- Chen, L., & Kumar, R. (2024). RAG systems: Bridging enterprise knowledge and LLMs. *Journal of Applied Artificial Intelligence*, 12(2), 68–82.
- Chen, X., & Wang, S. (2025, March 3). Pragmatic Inference Chain (PIC) Improving LLMs' reasoning of authentic implicit toxic language. arXiv. <https://doi.org/10.48550/arXiv.2503.01539>
- Christensen, C. M., Hall, T., Dillon, K., & Duncan, D. S. (2016). Know your customers' „jobs to be done“. *Harvard Business Review*, 94(9), 54–62.
- Dagkoulis, I., & Moussiades, L. (2023). *A comparative evaluation of Chatbot development platforms (PCI '22)*. ACM. <https://doi.org/10.1145/3575879.3576012>
- DataCamp. (2025). *A complete guide to data augmentation*. <https://www.datacamp.com/tutorial/complete-guide-data-augmentation>. Zugegriffen am 29.03.2025.
- Deep Tech Consulting GmbH. (2024, Dezember 07). *Wie man eine effektive LLM-Evaluierung durchführt, um ein optimales Ergebnis zu erzielen*. Medium. <https://medium.com/deep-tech-consulting-gmbh/wie-man-eine-effektive-llm-evaluierung-durchf%C3%BChrt-um-ein-optimales-ergebnis-zu-erzielen-6a3b9f28d5e7>. Zugegriffen am 28.03.2025.
- Dell'Acqua, F., McFowland, E., Mollick, E. R., Lifshitz-Assaf, H., Kellogg, K., Rajendran, S., Krayner, L., Candelon, F., & Lakhani, K. R. (2023). *Navigating the jagged technological frontier: Field experimental evidence of the effects of AI on knowledge worker productivity and quality* (Harvard Business School Technology & Operations Mgt. Unit Working Paper No. 24-013). https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4573321. Zugegriffen am 28.03.2025.

- Deloitte. (2024). *Tech trends 2025*. Deloitte Insights. <https://www2.deloitte.com/us/en/insights/focus/tech-trends.html>. Zugegriffen am 28.03.2025.
- Demarco, G., Fanelli, N., Vessio, G., & Castellano, G. (2024). Converso: Improving LLM Chatbot interfaces and task execution via conversational form. In *Proceedings of the 1st Workshop on Large Language Models for Human-Machine Interaction (LLM-HMI 2024)*. CEUR Workshop Proceedings. <https://ceur-ws.org/Vol-3720/paper-6.pdf>. Zugegriffen am 28.03.2025.
- Designveloper. (2025, Februar 18). *20 Open source Chatbot frameworks to use in 2025*. Designveloper Blog. <https://www.designveloper.com/blog/open-source-chatbot-frameworks/>. Zugegriffen am 28.03.2025.
- Desmond, M., & Brachman, M. (2024). *Exploring prompt engineering practices in the enterprise*. arXiv. <https://doi.org/10.48550/arXiv.2407.05053>
- Engati. (2025). *How does intent and entity in Chatbots work?* | Engati Blog. <https://www.engati.com/blog/intent-and-entity-in-chatbots>. Zugegriffen am 29.03.2025.
- Euronews. (2025, Januar 05). *What's in store for AI in 2025? Here's what Chatbots and experts say*. Euronews Next. <https://www.euronews.com/next/2025/01/05/whats-in-store-for-ai-in-2025-heres-what-chatbots-and-consulting-experts-say>. Zugegriffen am 28.03.2025.
- European Union. (2024). *AI Act*. Shaping Europe's digital future. <https://digital-strategy.ec.europa.eu/en/policies/ai-act>. Zugegriffen am 28.03.2025.
- Exovia. (2024). *Zielgruppenanalyse: Definition, Methoden und Praxisbeispiele*. <https://www.exovia.de/journal/zielgruppenanalyse/>. Zugegriffen am 28.03.2025.
- EY. (2025). *EY reimagining industry futures study 2025*. EYGM Limited.
- Fieldfisher. (2023, Oktober 10). *Generative KI: Bias, Halluzinationen und DSGVO*. Fieldfisher Insights. <https://www.fieldfisher.com/de-de/insights/generative-ki-bias-halluzinationen-und-dsgvo>. Zugegriffen am 28.03.2025.
- Fischer, C., Willems, J., & Van den Bergh, J. (2021). *Neue Technologien im öffentlichen Sektor: Bürgerinnen und Bürger haben nur geringe Erwartungen*. Verwaltung & Management.
- Futureofvoice.com. (2021). *Chatbots lernen: Optimierungsprozesse nach Go-Live*. Future of Voice Blog. <https://www.futureofvoice.com/blog/chatbots/chatbots-und-optimierungsprozesse-vom-go-live-zum-go-great>. Zugegriffen am 28.03.2025.
- Gallegos, I. O., Rossi, R. A., Barrow, J., Balashankar, A., & Rong, Y. (2023). *Bias and fairness in large language models: A survey*. arXiv. <https://doi.org/10.48550/arXiv.2309.00770>
- Gao, M., Liu, X., Xu, A., & Akkiraju, R. (2021). Chatbot or Chat-Blocker: Predicting Chatbot Popularity before Deployment. In *Proceedings of the 2021 ACM Designing Interactive Systems Conference* (S. 934–945). <https://doi.org/10.1145/3461778.3462014>
- Ghosh, A., & Deepa, K. (2024). QueryMintAI: Multipurpose multimodal large language models for personal data. *IEEE Access*, 12, 36988–37001. <https://doi.org/10.1109/ACCESS.2024.3374899>
- Giuri, M. (2023). *Walmart verknüpft Chatbot mit Warenkorb*. Lebensmittel Zeitung.
- Gong, Z., Birajdar, S., Cao, T., Khoo, Y. Q., Chung, C.-F., Moghaddam, Y., Xu, A., Mehta, H., Shukla, A., Wang, Z., & Akkiraju, R. (2024). Enhancing trust in LLM chatbots for workplace support through user experience design and prompt engineering. In C. Leitner, R. Nägele, C. Bassano, & D. Satterfield (Hrsg.), *The human side of service engineering* (Bd. 143, S. 139–149). AHFE Open Access. <https://doi.org/10.54941/ahfe1005092>
- Goodman, B. (2023, July 24). A guide to prompt injection attacks and defenses. *IEEE Spectrum*. <https://spectrum.ieee.org/prompt-injection-attacks-llms>. Zugegriffen am 28.03.2025.
- Google Cloud. (o.J.). *Conversational Agents (Dialogflow CX) documentation*. Google Cloud Documentation. <https://cloud.google.com/dialogflow/cx/docs>. Zugegriffen am 29.03.2025.
- Google DeepMind. (2023, Dezember 06). *Introducing Gemini: our largest and most capable AI model*. Google Blog. <https://blog.google/technology/ai/google-gemini-ai/>. Zugegriffen am 28.03.2025.
- Grand View Research. (2024). *Chatbot market size, share & growth | Industry report, 2030*. <https://www.grandviewresearch.com/industry-analysis/chatbot-market>. Zugegriffen am 28.03.2025.
- Grandi, D., Jain, Y., Groom, A., Cramer, B., & McComb, C. (2024). *Evaluating large language models for material selection*. arXiv. <https://doi.org/10.48550/arXiv.2406.02050>

- Harahap, N. S., Saad, A., & Ubaidullah, N. H. (2025). Comprehensive bibliometric literature review of Chatbot research: Trends, frameworks, and emerging applications. *International Journal of Advanced Computer Science and Applications*, 16(1). <https://www.semanticscholar.org/paper/3c0a9fa429c926277d32464e2708f253cc833074>. Zugegriffen am 28.03.2025.
- Haresamudram, K., Van As, N., & Larsson, S. (2025). Tasks over traits: User perception of humanlike features in goal-oriented Chatbots. *International Journal of Human–Computer Interaction*, 41(21), 13363–13381. <https://doi.org/10.1080/10447318.2025.2470311>
- Hartmann, F., & Weber, S. (2024). *Hybride Chatbot-Architekturen: Praxisleitfaden für Unternehmensanwendungen*. Springer Fachmedie. <https://doi.org/10.1007/978-3-658-44079-4>
- Hasegawa, K., Hidano, S., & Fukushima, K. (2024). RAG certainty: Quantifying the certainty of context-based responses by LLMs. In *2024 International Conference on Machine Learning and Applications (ICMLA)* (S. 912–917).
- Hnatushenko, V., Ostrovska, K., & Nosov, V. (2024). Development and research of a Chatbot using the linguistic core of Amazon Lex V2. In *International Conference on Computational Linguistics and Intelligent Systems*. <https://www.semanticscholar.org/paper/4cabb83e3a1679c1b2561ad4c53782014daa5a0>. Zugegriffen am 28.03.2025.
- Ho-Dac, M. (2024). *First analysis of the EU Artificial Intelligence Act: towards a global standard for trustworthy AI?* arXiv. <https://doi.org/10.48550/arXiv.2407.01420>
- Hong, Z., et al. (2025). *Next-generation database interfaces: A survey of LLM-based Text-to-SQL*. arXiv. <https://doi.org/10.48550/arXiv.2406.08426>
- Huang, L., Qiu, L., Foroudi, P., & Foroudi, M. M. (2024). Can Chatbot customer service match human service? The roles of communication style, trust, and cultural context. *Journal of Business Research*, 177, 103673. <https://doi.org/10.1016/j.jbusres.2024.103673>
- Hundertmark, S. (2020). *Digitale Freunde: Wie Unternehmen Chatbots erfolgreich einsetzen können*. Wiley-VCH.
- Janssen, A., Cardona, D. R., Passlick, J., & Breitner, M. H. (2022). How to make Chatbots productive – Development and evaluation of a user-oriented implementation framework. *International Journal of Human – Computer Studies*, 168, 102921. <https://doi.org/10.1016/j.ijhcs.2022.102921>
- Jasmin, A., Ramesh, P., & Tanveer, M. (2022). Development of Artificial Intelligence-based Chatbot for smart aquafarm practices. *Expert Systems*, 41(6), e13123. <https://doi.org/10.1111/exsy.13123>.
- Jegan, J. A., & Akilandeswari, J. (2023). Chatbot for Start-Ups and entrepreneurs with conversational AI and NLP techniques. In *2023 7th International Conference on Computing Methodologies and Communication (ICCMC)* (S. 1320–1325). <https://doi.org/10.1109/ICCMC56507.2023.10084191>
- Joshi, S., Khan, M. S., Dafe, A., Singh, K., Zope, V., & Jhamtani, T. (2024). Fine tuning LLMs for low resource languages. In *2024 5th International Conference on Image Processing and Capsule Networks (ICIPCN)* (S. 1125–1129). <https://doi.org/10.1109/ICIPCN60784.2024.10585644>
- Kabbay, H. S. (2024). Streamlining AI application: MLOps best practices and platform automation illustrated through an advanced RAG based Chatbot. In *2024 2nd International Conference on Sustainable Computing and Smart Systems (ICSCSS)*.
- Kalakuntla, S. T., Lankapothu Sai, T. R., Lankapothu Pavan, K. R., & Uppaluri, N. M. (2023). Multimodal LLMS: Combining text and images for enhanced understanding. *International Journal of Research Publication and Reviews*, 4(11), 1343–1350.
- Kale, V., Rana, K., Wade, A., Patel, K., & Sirsat, A. (2025). Conversational Chatbot with RASA for Educational Facilitation. In *2025 6th International Conference on Mobile Computing and Sustainable Informatics (ICMCSI)* (S. 267–272).
- Khan, S., & Orii, L. (2024). Transformer models: Beyond BERT. *Artificial Intelligence Review*, 57(3), 58. <https://doi.org/10.1007/s10462-023-10520-5>

- Kiran, R. P., Khaiyum, S., Palandye, A. R., Apoorva, S. D., Arjun, R., Akshaya, S. A., & Annappoorna, S. (2024). Leveraging LLaMA3 and LangChain for rapid AI application development. *Journal of Electrical Systems*, 20(10s), 2146–2153. <https://doi.org/10.52783/jes.5539>
- Knight, W. (2023, Oktober 12). *The Chatbots are now talking to each other*. WIRED. <https://www.wired.com/story/the-chatbots-are-now-talking-to-each-other/>. Zugegriffen am 28.03.2025.
- Koseva Stefanova, A. N. (2023). Change management in the implementation of AI technology – Organizational aspects. In *Proceedings of the 6th International Conference on Advanced Research in Management, Business and Finance*.
- Kumar, S. (2024, Dezember 18). *Meta's final big AI update of 2024: Launch of Llama 3.3*. LinkedIn. <https://www.linkedin.com/pulse/metass-final-big-ai-update-2024-launch-llama-33-sani-kumar-x2ymc>. Zugegriffen am 28.03.2025.
- Lakshmi Swathi Sreedhar. (2024). Speak the language of AI: Mastering prompt engineering for LLMs. *Proceedings of the International Conference on Industrial Engineering and Operations Management*, 14(1), 4146–4155. <https://doi.org/10.46254/AN14.20240716>
- Lee, C.-H., Low, M. Y. H., Soon, B. T. C., Lu, L., Lee, H., & Patel, N. S. (2022). Development of a Chatbot to train physiotherapy students in clinical questioning and reasoning. In *2022 IEEE International Conference on Teaching, Assessment and Learning for Engineering (TALE)*.
- Lee, J., Chen, F., Dua, S., Cer, D., Shanbhogue, M., Naim, I., Hernández Ábrego, G., ... & Hoffmann, R. (2025). *Gemini embedding: Generalizable embeddings from Gemini*. ArXiv. <https://doi.org/10.48550/arXiv.2503.07891>
- Leschansowsky, A., Popp, B., & Peters, N. (2023). *Privacy strategies for conversational AI ...* (EuroUSEC '23, ACM). <https://doi.org/10.1145/3617072.3617106>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- Li, H., Leung, J., & Shen, Z. (2024a). *Towards goal-oriented prompt engineering for large language models: A survey*. ArXiv. <https://doi.org/10.48550/arXiv.2401.09126>
- Li, H., Liu, Y., Cheng, Y., Ray, S., Du, K., & Jiang, J. (2024b). *Chatterbox: Robust transport for LLM token streaming under unstable network*. ArXiv, abs/2401.12961.
- Li, J., Cheng, X., Zhao, W. X., Nie, J.-Y., & Wen, J.-R. (2023, Mai 22). *HaluEval: A large-scale hallucination evaluation benchmark for large language models* [Preprint]. arXiv. <https://doi.org/10.48550/arXiv.2305.11747>
- Li, K., Zhang, L., Jiang, Y., Xie, P., Huang, F., Wang, S., & Cheng, M. (2025). *LaRA: Benchmarking retrieval-augmented generation and long-context LLMs – No Silver bullet for LC or RAG routing*. ArXiv, abs/2502.09977.
- Lin, L., Luo, Z., Zhao, Z., Haffari, G., Phung, D. Q., Gong, C., & Pan, S. (2025). *GFM-RAG: Graph foundation model for retrieval augmented generation*. arXiv. <https://doi.org/10.48550/arXiv.2407.03128>
- Liu, X., Yu, H., Ahn, J., Zhang, J., Park, J., Li, X., ... Tang, J. (2023, August 07). *AgentBench: Evaluating large language models as agents*. arXiv. <https://doi.org/10.48550/arXiv.2308.03688>
- Luchaninov, J. (2025, Januar 16). *Chatbot development guide: How to build a Chatbot that brings real value for your business*. MobiDev. <https://mobidev.biz/blog/chatbot-development-guide>. Zugegriffen am 28.03.2025.
- Luo, L., Zhao, Z., Haffari, G., Phung, D., Gong, C., & Pan, S. (2025). *GFM-RAG: Graph foundation model for retrieval augmented generation*. ArXiv, abs/2502.01113.
- Lyngdoh, F. B., & Raghavendra, R. (2022). Chatbot. *International Journal for Research in Applied Science & Engineering Technology (IJRASET)*, 10(3), 588–590. <https://doi.org/10.22214/ijraset.2022.40587>
- MarketsandMarkets. (2024). *Chatbot Market Share, Forecast | Growth Analysis and Trends Report [2032]*. <https://www.marketsandmarkets.com/Market-Reports/chatbot-market-72302363.html>. Zugegriffen am 28.03.2025.
- Masterofcode.com. (2026, Januar 27). *Chatbot Statistics: How AI Is Powering the Rise of Digital Assistants* Abgerufen von <https://masterofcode.com/blog/chatbot-statistics>

- Masterofcode.com. (2024, Oktober 24). *40+ Chatbot statistics for 2024 (Usage, market share & trends)*. Master of Code Blog. <https://masterofcode.com/blog/chatbot-statistics>
- McKinsey Superagency. (2025, Januar). *Superagency in the workplace: Empowering people to unlock AI's full potential*. McKinsey & Company.
- McKinsey Global Institute. (2025, January). *Superagency in the workplace: Empowering people to unlock AI's full potential*. McKinsey & Company. <https://www.mckinsey.com/capabilities/tech-and-ai/our-insights/superagency-in-the-workplace-empowering-people-to-unlock-ais-full-potential-at-work>
- Meduri, V. (2024). Revolutionizing customer service: A comprehensive analysis of conversational AI and Large Language Models (LLMs). *Journal of Artificial Intelligence and Technology*, 4(2), 8. <https://doi.org/10.37965/jait.2024.10065>
- Mehrpour, B., & Pezzelle, S. (2024). Detecting and translating language ambiguity with multilingual LLMs. In *Proceedings of the Fourth Workshop on Multilingual Representation Learning (MRL 2024)* (S. 156–168). Association for Computational Linguistics.
- Mhatre, A., Warhade, S. R., Pawar, O., Kokate, S., Jain, S., & Emmanuel, M. (2024). Leveraging LLM: Implementing an Advanced AI Chatbot for Healthcare. *International Journal of Innovative Science and Research Technology (IJISRT)*.
- Microsoft. (2023). *Microsoft work trend index annual report: Will AI fix work?* <https://www.microsoft.com/en-us/worklab/work-trend-index/will-ai-fix-work>. Zugegriffen am 28.03.2025.
- Microsoft Learn. (2025). *Utterances – Azure AI services | Microsoft Learn*. <https://learn.microsoft.com/en-us/azure/ai-services/luis/concepts/utterances>. Zugegriffen am 29.03.2025.
- Mil, J. van, & Quintais, J. P. (2022) A matter of (joint) control? Virtual assistants and the GDPR. *Computer Law & Security Review*, 45, 105689. <https://doi.org/10.1016/j.clsr.2022.105689>
- Mökander, J., Carlier, A., Schuett, J., & Webb, H. (2023). Ethics-based auditing for AI governance. *Minds and Machines*, 33(1), 103–120. <https://doi.org/10.1007/s11023-023-09630-0>
- Nowakowski, G., Telenyk, S. F., & Vovk, Y. (2023). Chatbots lifecycle support platform. *2023 IEEE 17th International Conference on Intelligent Data Acquisition and Advanced Computing Systems: Technology and Applications (IDAACS)*, 1, 504–508. <https://doi.org/10.1109/idaacs58523.2023.10348794>
- Nze, S. U. (2024). AI-Powered Chatbots. *Global Journal of Human Resource Management*, 12(6), 34–45. <https://doi.org/10.37745/gjhrm.2013/vol12n63445>
- OpenAI. (2023). *GPT-4 technical report*. arXiv preprint arXiv:2303.08774. <https://arxiv.org/abs/2303.08774>. Zugegriffen am 28.03.2025.
- Pandey, O. (2019). *Artificial Intelligence and conventional computing*. ResearchGate. https://www.researchgate.net/publication/330655022_Artificial_Intelligence_and_Conventional_Computing. Zugegriffen am 28.03.2025.
- Park, E.-Y. (2022). Effects of consumer loneliness on Chatbot recommendation intention: Moderating effects of Chatbot conversation style. *Journal of the Korean Society of Supply Chain Management*, 22(3), 107–119. <https://doi.org/10.25052/KSCM.2022.10.22.3.107>
- Pereira, J., & Díaz, Ó. (2018). Chatbot Dimensions that Matter: Lessons from the Trenches. In T. Mikkonen, R. Klamma, & J. Hernández (Hrsg.), *Web engineering. 18th International Conference, ICWE 2018, Cáceres, Spain, June 5–8, 2018: Proceedings* (S. 129–135). Springer.
- Pradana, Z. H., Nafi'ah, H., & Rochmanto, R. A. (2022). Chatbot-based Information Service using RASA Open-Source Framework in Prambanan Temple Tourism Object. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 6(4), 656–662.
- Privacy International. (2024, August 14). *Large language models and data protection*. <https://privacyinternational.org/explainer/5406/large-language-models-and-data-protection>. Zugegriffen am 28.03.2025.
- Przegalinska, A., Ciechanowski, L., Stroz, A., Gloor, P., & Mazurek, G. (2019). In bot we trust: A new methodology of Chatbot performance measures. *Business Horizons*, 62(6), 785–797. <https://doi.org/10.1016/j.bushor.2019.08.005>
- PwC. (2024). *2024 Cloud and AI business survey*. PwC. <https://www.pwc.com/us/en/tech-effect/cloud/cloud-ai-business-survey.html>. Zugegriffen am 28.03.2025.

- Qin, Y., Liang, S., Ye, Y., Zhu, K., Yan, L., Lu, Y., ... Sun, M. (2023). *ToolLLM: Facilitating large language models to master 16 000+ real-world APIs* (arXiv No. 2307.16789). <https://doi.org/10.48550/arXiv.2307.16789>
- Qualimero. (2025, Februar 17). *Conversational AI Firmen im DACH-Raum 2025: Marktführer & Trends*. Qualimero Blog. <https://www.qualimero.com/de/blog/dach-conversational-ai-firmen>. Zugegriffen am 28.03.2025.
- Rathod, P. J., & Anurag. (2024). Efficient usage of RAG systems in the world of LLMs. *International Journal for Multidisciplinary Research (IJFMR)*, 6(4), 1–6. <https://doi.org/10.36948/ijfmr.2024.v06i04.36364>
- Ratio, C. A., Brennan, N., Williams, J., Kaplan, A., Williams, S., & Insa, M. (o.J.). Optimizing automuse with GPT-4 Turbo-128k.
- Ren, E. (2024). *Task scheduling for decentralized LLM serving in heterogeneous networks*. Semantic Scholar.
- Rességuier, A., & Ufert, F. (2023). AI research ethics is in its infancy: the EU's AI Act can make it a grown-up. *Research Ethics*, 19(4), 450–464. <https://doi.org/10.1177/17470161231192130>
- Schmidt, M., & Müller, J. (2023). *Conversational AI 2.0: LLM-basierte Kundeninteraktionen*. Hanser.
- Schulhoff, S., Ilie, M., Balepur, N., Kahadze, K., Liu, A., Si, C., Li, Y., Gupta, A., Han, H., Schulhoff, S., Dulepet, P. S., Vidyadhara, S., Ki, D., Agrawal, S., Pham, C., Kroiz, G. C., Li, F., Tao, H., Srivastava, A., ... Resnik, P. (2024). *The prompt report: A systematic survey of prompt engineering techniques*. arXiv. <https://doi.org/10.48550/arXiv.2406.10095>
- Service Innovation. (2024). *Conversation design: Skills and strategies for Chatbots*. Service Innovation Blog. <https://www.serviceinnovation.org/conversation-design-skills-and-strategies-for-chatbots/>. Zugegriffen am 28.03.2025.
- Shang, S., Zhao, X., Yao, Z., Yao, Y., Su, L., Fan, Z., Zhang, X., & Jiang, Z. (2024). *Can LLMs deeply detect complex malicious queries? A framework for jailbreaking via obfuscating intent*. ArXiv. <https://arxiv.org/abs/2402.11113>
- Sharma, K., Kumar, P., & Li, Y. (2024). *OG-RAG: Ontology-grounded retrieval-augmented generation for large language models*. arXiv. <https://doi.org/10.48550/arXiv.2406.17574>
- Skuridin, A., & Wynn, M. (2024). Chatbot design and implementation: Towards an operational model for Chatbots. *Information*, 15(4), 226. <https://doi.org/10.3390/info15040226>
- SpringsApps. (2025). *The evolution of Chatbot Intents: Everything you need to know*. <https://springsapps.com/knowledge/the-evolution-of-chatbot-intents-everything-you-need-to-know>. Zugegriffen am 29.03.2025.
- Stallone, M., Saxena, V., Karlinsky, L., McGinn, B., Bula, T., Mishra, M., Soria, A.M., Zhang, G., Prasad, A., Shen, Y., Surendran, S., Guttula, S.C., Patel, H., Selvam, P., Dang, X., Koymann, Y., Sood, A., Feris, R., Desai, N., Cox, D.D., Puri, R., & Panda, R. (2024). *Scaling granite code models to 128K context*. ArXiv, abs/2407.13739.
- Statista. (2025, Februar). *Most popular global mobile messenger apps as of February 2025, based on number of monthly active users*. Statista. <https://www.statista.com/statistics/258749/most-popular-global-mobile-messenger-apps/>. Zugegriffen am 28.03.2025.
- Straelen, M. van, & Schleuss, S. (2023). Erfolg durch digitale Transformation und Nachhaltigkeit: Die perfekte Symbiose. *Wirtschaftsinformatik & Management*, 15(4), 300–303. <https://doi.org/10.1365/s35764-023-00488-w>
- Tai, C. A., & Tannier, X. (2025). *Clinical trial cohort selection using Large Language Models on n2c2 Challenges*. arXiv. <https://doi.org/10.48550/arXiv.2405.19508>
- Tamoyan, H., Schuff, H., & Gurevych, I. (2024). *LLM roleplay: Simulating Human-Chatbot Interaction*. arXiv. <https://doi.org/10.48550/arXiv.2402.16236>
- Technobase. (2024). *10 Biggest trends and innovations in AI Chatbot 2025*. Technobase Blog. <https://technobase.in/10-biggest-trends-and-innovations-in-ai-chatbot-2025/>. Zugegriffen am 28.03.2025.
- The Barrister Group. (2025). *Understanding the GDPR and EU AI Act: Key insights for businesses*. <https://thebarristergroup.co.uk/blog/understanding-the-gdpr-and-eu-ai-act-key-insights-for-businesses>. Zugegriffen am 29.03.2025.

- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., ... Lample, G. (2023). *LLaMA: Open and efficient foundation language models*. arXiv preprint arXiv:2302.13971. <https://arxiv.org/abs/2302.13971>. Zugegriffen am 28.03.2025.
- Twilio. (2020). *Global study consumer engagement best practices for 2020*. Twilio. <https://ahoy.twilio.com/global-consumer-engagement-study> (Originalquelle, referenziert). Zugegriffen am 28.03.2025.
- Userlike. (2024). *Chatbot design tips, best practices, details for 2025*. Userlike Blog. <https://www.userlike.com/en/blog/chatbot-design>. Zugegriffen am 28.03.2025.
- VASS. (2024). *5 tips to help you maintain and improve your Chatbot*. VASS Company Insights. <https://vasscompany.com/en/insights/blogs-articles/maintain-improve-chatbot/>. Zugegriffen am 28.03.2025.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30, 1–9.
- Verloop.io. (2025). *Intents and entities in a Chatbot*. Verloop.io Blog. <https://www.verloop.io/blog/intents-and-entities/>. Zugegriffen am 29.03.2025.
- Wang, L., Ma, C., Feng, X., Zhang, Z., Yang, H., Zhang, J., ... & Wang, X. (2023). *A survey on large language model based autonomous agents*. arXiv preprint arXiv:2308.11432. <https://arxiv.org/abs/2308.11432>. Zugegriffen am 28.03.2025.
- Wei, T., Hong, J., Cao, Z., Ma, J., & Chan, P. P. K. (2024). *LLM as an egocentric vision assistant*. arXiv preprint arXiv:2407.08520.
- Winkler, R., Oppong, E., Berger, B., & Grewal, D. (2023). Hyperpersonalization: A comprehensive review, framework, and future research agenda. *Journal of the Academy of Marketing Science*, 51(6), 1315–1344. <https://doi.org/10.1007/s11747-023-00968-9>
- Xue, V. W. (2024). *A comprehensive survey on syntax-aware large language models*. arXiv preprint arXiv:2405.15594. <https://arxiv.org/abs/2405.15594>. Zugegriffen am 28.03.2025.
- YouGPT.ai. (2025). *Open AI O3 vs GPT-4: Top differences that you should know in 2025*. YouGPT.ai Blog. <https://yougpt.ai/blog/updates/open-ai-o3-vs-gpt-4-top-differences-that-you-should-know-in-2025> (Referenz für O3-Details). Zugegriffen am 28.03.2025.
- Yu, H., Gan, A., Zhang, K., Tong, S., Liu, Q., & Liu, Z. (2024, Juli 03). *Evaluation of retrieval-augmented generation: A survey*. arXiv. <https://doi.org/10.48550/arXiv.2405.07437>
- Zhang, H., Li, Z., Liu, F., He, Y., Cao, Z., & Zheng, Y. (2024). Design and implementation of LangChain-based Chatbot. In *2024 International Seminar on Artificial Intelligence, Computer Technology and Control Engineering (ACTCE)* (S. 296–301). <https://doi.org/10.1109/ACTCE62211.2024.10690550>
- Zhou, Y., Muresanu, A. I., Han, Z., Paster, K., Pitis, S., Chan, H., & Ba, J. (2023). *Large language models understand and can be enhanced by emotional stimuli*. arXiv preprint arXiv:2307.11760. <https://arxiv.org/abs/2307.11760>. Zugegriffen am 28.03.2025.
- Zhou, Z., Zhang, Q., Kumbong, H., & Olukotun, K. (2025). *LowRA: Accurate and efficient LoRA fine-tuning of LLMs under 2 Bits*. arXiv. <https://doi.org/10.48550/arXiv.2406.19832>
- Zumstein, D., & Hundertmark, S. (2017). Chatbots – An interactive technology for personalized communication, transaction and services. *IADIS International Journal on WWW/Internet*, 15(1), 96–109.

Julia Lehmann ist Expertin für Kundenservice, Customer Experience und Conversational AI. Sie leitete zahlreiche Digitalisierungsprojekte führender Unternehmen, auch von DAX-Konzernen. Als Gründerin von OnFore unterstützt sie Unternehmen bei der strategischen und technischen Entwicklung digitaler Geschäftsmodelle und Lösungen, insbesondere im Bereich künstliche Intelligenz. Seit 2019 gibt Julia Lehmann ihre Expertise zudem als Dozentin für Digitales Marketing & Management (MBA) an der Hochschule für Wirtschaft und Umwelt Nürtingen-Geislingen (HfWU) weiter. Sie arbeitet außerdem als Gutachterin für den Marketing Review St. Gallen.